

Instituto Tecnológico y de Estudios Superiores de Monterrey

Campus Toluca

*DESARROLLO DE APLICACIONES AVANZADAS DE CIENCIAS
COMPUTACIONALES (GPO 501)*

Guía de Instalación y Despliegue del Sistema RAT

Presenta:

Santiago Albarrán Organista	A01369828
Victor Alonzo Estévez Chávez	A01769388
Miguel Ángel Pérez Ávila	A01369908
Alyson Melissa Sánchez Serratos	A01771843
Alberto Isaac Sánchez Tarango	A01771321
Máximo Moisés Zamudio Chávez	A01772056

Tabla de Contenido

GUÍA DE DESPLIEGUE DEL SISTEMA RAT EN INFRAESTRUCTURA DE AMAZON WEB SERVICES 1

CONFIGURACIONES PREVIAS	1
<i>Instalación de Docker</i>	1
Instalación en Linux	1
Instalación en Mac y Windows	1
Verificación de instalación.....	2
<i>Creación y Configuración de una Cuenta para Amazon Web Services</i>	2
Creación de una Cuenta en Gmail.....	2
Creación de una Cuenta en Amazon Web Services	2
<i>Configuración y Creación de una Instancia S3</i>	2
Subir los Archivos de Parámetros del Modelo Entrenado y Crear Carpeta para Imágenes	2
<i>Configuración de la Command Line Interface (CLI) para AWS</i>	3
Instalación de la CLI de AWS	3
Configuración de un Perfil en la CLI de AWS.....	3
<i>Creación de un rol en IAM</i>	4
<i>Configuración y Creación de Amazon Elastic Container Registry (ECR)</i>	5
Autenticación en Amazon ECR.....	5
Configuración del Repositorio en AWS Elastic Container Registry (ECR).....	5
DESPLIEGUE DEL SISTEMA RAT EN INFRAESTRUCTURA DE AMAZON WEB SERVICES	5
<i>Documentación sobre los Servicios Utilizados</i>	5
Amazon Elastic Compute Cloud (EC2)	5
Nginx	6
Vercel	6
Certbot	6
<i>Configuración de la EC2</i>	6
Creación de la Instancia EC2	6
Conexión por SSH a la Instancia EC2.....	7
Configuración de un Nombre de Dominio para la Conexión con la EC2 mediante DNS	7
Configuración del Sistema RAT dentro de la EC2.....	8
Configuración de Ubuntu	8
Instalación de Composer.....	8
Clonación del Backend desde Github	9
Instalar Dependencias con Composer.....	9
Creación del Archivo .env.....	9
Permisos de Carpetas.....	9
Configuración de Nginx.....	10
Prueba Local desde la EC2.....	10
Configuración de HTTPS con Certbot.....	10
<i>Configuración de Vercel para el Despliegue del Frontend</i>	11
Creación de una cuenta en Vercel.....	11
Despliegue del Frontend en Vercel	11
DESPLIEGUE DE MODELOS EN AMAZON WEB SERVICES	12
<i>Documentación sobre los Servicios Utilizados</i>	12
Docker.....	12
Amazon Elastic Container Registry.....	12
Amazon Lambda	12

Amazon S3.....	12
<i>Despliegue de los Modelos</i>	13
Configuración de la Imagen en Docker	13
Construcción de la Imagen en Docker	13
Importancia del Etiquetado para la Versión de la Imagen	13
Publicación de la Imagen de Docker en Amazon ECR	14
Creación de la Función Lambda a partir de la Imagen	14
Creación de la función Lambda	14
Actualización del Código de la Función	14
Creación y Configuración de la API Gateway para la Función Lambda	15
Creación de la API	15
Habilitación de CORS	15
Configuración para CORS en la API Gateway	15
Prueba de Funcionamiento sin Cliente Web	16
Invocación Especial sin Imagen.....	16
Invocación con Imagen	16
Carga de una Imagen de Ejemplo en S3.....	16
Invocación de la Función Lambda con la Imagen de Ejemplo en S3 en la AWS CLI	16
Modelo de Inteligencia Artificial Basado en Visión Computacional	17
Modelo Híbrido	17
Invocación de la Función Lambda con la Imagen de Ejemplo en S3 en la API Gateway	17
Modelo de Inteligencia Artificial Basado en Visión Computacional	17
Modelo de Inteligencia Artificial Híbrido	18
Invocación de la Función Lambda con la Imagen de Ejemplo en S3 en el Sistema RAT	18

Guía de Despliegue del Sistema RAT en Infraestructura de Amazon Web Services

Configuraciones Previas

Instalación de Docker

Instalación en Linux

1. Actualizar el índice de paquetes con el comando *sudo apt-get update*
2. Instalar paquetes de prerequisites con el comando *sudo apt-get install apt-transport-https ca-certificates curl software-properties-common -y*
3. Agregar la clave GPG oficial de Docker *curl -fsSL https://download.docker.com/linux/ubuntu/gpg | sudo gpg --dearmor -o /usr/share/keyrings/docker-archive-keyring.gpg*
4. Configurar el repositorio estable *echo "deb [arch=\$(dpkg --print-architecture) signed-by=/usr/share/keyrings/docker-archive-keyring.gpg] https://download.docker.com/linux/ubuntu \$(lsb_release -cs) stable" | sudo tee /etc/apt/sources.list.d/docker.list > /dev/null*
5. Instalar el Docker Engine *sudo apt-get update sudo apt-get install docker-ce docker-ce-cli containerd.io docker-compose-plugin -y*

Instalación en Mac y Windows

La mejor opción es la instalación de Docker Desktop, esto incluye la interfaz gráfica, motor Docker (Docker Engine) y Docker Compose.

1. Descarga el instalador, da clic [aquí](#) y descargar el instalador correspondiente al sistema operativo (en Windows, es necesario cumplir con el requisito de tener WSL 2 instalado; en macOS, se debe elegir el instalador según el procesador, Intel o Apple Silicon).
2. Ejecutar el instalador siguiendo los pasos del asistente visual (doble clic en el archivo .exe o .dmg).
3. Inicio del servicio, abrir la aplicación de Docker Desktop. Se mostrará un icono de una ballena en la barra de tareas o barra de menús indicando que el servicio se está iniciando. Una vez que cambie a color verde, Docker estará listo.

Verificación de instalación

1. Independientemente del sistema operativo, abrir una terminal o línea de comandos y ejecutar:

docker --version

docker compose version

Creación y Configuración de una Cuenta para Amazon Web Services

Creación de una Cuenta en Gmail

1. Dar clic [aquí](#) para ingresar a un tutorial que guiará la creación de una cuenta de Gmail.
2. Seguir los pasos que se indiquen para la creación de la cuenta de Gmail.

Creación de una Cuenta en Amazon Web Services

1. Dar clic [aquí](#) para ingresar a un tutorial que guiará la creación de una cuenta en Amazon Web Services. Es importante mencionar que se hará uso de la cuenta que fue creada en la sección *Creación de una Cuenta en Gmail*.
1. Entrar al siguiente enlace:
https://signin.aws.amazon.com/signup?request_type=register&refid=24053cb6-314c-4f31-a3de-6b2fa3b71ec1
2. Asegúrese de seleccionar el plan gratuito para continuar con las secciones subsecuentes de esta guía. Se le solicitará ingresar un método de pago, su único propósito es por parte de validaciones correspondientes a Amazon Web Services y no se realizará ningún cargo a la cuenta por el uso de los servicios si se ha seleccionado el plan gratuito tal y como se indicó en el paso anterior.

Configuración y Creación de una Instancia S3

1. Ingresar a la consola de *AWS*.
2. Seleccionar el servicio *S3*.
3. Dar clic en el botón para crear un *bucket*.
4. Establecer la siguiente configuración para el *bucket*:
 - a) Tipo de *bucket*: uso general.
 - b) Espacio de nombres del *bucket*: *global*.
 - c) Nombre del *bucket*: *ai-vel-bucket*.
5. Mantener las demás configuraciones con los valores predeterminados.

Subir los Archivos de Parámetros del Modelo Entrenado y Crear Carpeta para Imágenes

1. Da clic [aquí](#) para acceder al archivo de pesos correspondiente al modelo basado en visión computacional. El archivo recibe por nombre *ImagVelEst_aug_ModFc_EmbHead_l1Loss_v1_weights.pth* y deberá ser descargado.

2. Da [clic](#) aquí para acceder al archivo de pesos correspondiente al modelo dual. El archivo recibe por nombre *HybVelEst_wLoss_ModFc_v2_weights.pth* y deberá ser descargado.
3. Dirígete a la consola de AWS y busca el servicio S3.
4. Si todos los pasos anteriores fueron llevados a cabo con éxito, deberá presentarse un bucket denominado *ai-vel-bucket*. Dar clic sobre él.
5. Seleccionar la opción *Crear carpeta*, colocar el nombre *ai-hyb-model* y mantener las configuraciones predeterminadas.
6. Volver a seleccionar la opción *Crear carpeta*, colocar el nombre *ai-image-model* y mantener las configuraciones predeterminadas.
7. Nuevamente, seleccionar la opción *Crear carpeta*, colocar el nombre *images* y mantener las configuraciones predeterminadas.
8. Acceder a la carpeta *ai-hyb-model*, seleccionar *Cargar*, posteriormente dar clic en *Agregar archivos* y elegir aquel que fue descargado y que recibe el nombre *HybVelEst_wLoss_ModFc_v2_weights.pth*, dejando las opciones restantes como predeterminadas.
9. Acceder a la carpeta *ai-image-model*, seleccionar *Cargar*, posteriormente dar clic en *Agregar archivos* y elegir aquel que fue descargado y que recibe el nombre *ImagVelEst_aug_ModFc_EmbHead_l1Loss_v1_weights.pth*, dejando las opciones restantes como predeterminadas.

Configuración de la Command Line Interface (CLI) para AWS

Instalación de la CLI de AWS

1. Instalar AWS CLI con el comando correspondiente al sistema operativo:
 - a. macOS: *brew install awscli*
 - b. Windows: *winget install Amazon.AWSCLI*
 - c. Linux: *sudo apt update sudo apt install awscli-y*
2. Verificar que la instalación se realizó correctamente: *aws--version 4*
3. Configurar las credenciales de AWS:
 - a. Ejecutar: *aws configure*
 - b. Ingresar los datos solicitados por el asistente.
 - c. Para la región, seleccionar la misma en la que se creó el *bucket S3*.
 - d. Definir json como formato de salida predeterminado.
4. Verificar la configuración con el siguiente comando. Si no se obtiene salida, se puede continuar: *aws s3 ls s3://ai-vel-bucket*

Configuración de un Perfil en la CLI de AWS

1. Ingresar el comando *aws login --profile <nombre perfil>*

Nota: En caso de no configurarse al perfil recientemente creado como el default, en los comandos siguientes de debe ingresar al final del comando -- profile <nombre

- perfil*>. En caso contrario, si se desea asignar el perfil actual como default temporalmente, se debe ejecutar *export AWS_PROFILE=<nombre del perfil>*
2. Ingresar la región donde se alojaron los servicios, ejemplo *us-east-2* correspondiente a Ohio.
 3. Se desplegará una página web, seleccionar la cuenta de *root*.

Creación de un rol en IAM

1. Ejecutar el comando.
`cd model/src/ImageVelocityEstimator/Deployment`
2. Crear un rol con el siguiente comando.
`aws iam create-role --role-name lambda-execution-role --assume-role-policy-document file://trust-policy.json`
3. Presionar la tecla “q”
4. Agregar permisos básicos al rol con el siguiente comando.
`aws iam attach-role-policy --role-name lambda-execution-role --policy-arn arn:aws:iam::aws:policy/service-role/AWSLambdaBasicExecutionRole`
5. Adjunta permisos al rol.
`aws iam put-role-policy --role-name lambda-execution-role --policy-name lambda-ai-vel-s3-policy --policy-document file://lambda-permissions-policy.json`
6. Agregar permisos básicos de logs.
`aws iam attach-role-policy --role-name lambda-execution-role --policy-arn arn:aws:iam::aws:policy/service-role/AWSLambdaBasicExecutionRole`
7. Ingresa los siguientes comandos para verificar que el rol cuenta con los permisos adecuados.
 - a. `aws iam get-role --role-name lambda-execution-role --query Role.AssumeRolePolicyDocument`
 - b. `aws iam list-role-policies --role-name lambda-execution-role`
 - c. `aws iam list-attached-role-policies --role-name lambda-execution-role`
8. Obtener y guardar el IAM_ROLE_ARN con el siguiente comando dado que será utilizado en secciones posteriores.
`aws iam get-role --role-name lambda-execution-role --query Role.Arn --output text`
9. Ingrese a la consola de *AWS* y busque el servicio *IAM*.
10. En el panel de la posición izquierda, seleccione la opción *Usuarios de IAM*.
11. Deberá ver listado su usuario recientemente creado, selecciónelo.
12. Seleccione la sección *Credenciales de Seguridad*.
13. Diríjase a la sección *Claves de acceso*, dé clic en el botón *Crear clave de acceso*.
 - a. El caso de uso es *Código local*.
 - b. Marque la casilla con la leyenda *Entiendo la recomendación anterior y deseo proceder a la creación de una clave de acceso*.
 - c. Dé clic en *Siguiente*.

14. Coloque el valor de etiqueta de descripción que desee, por ejemplo: `RAT_System_Key`.
15. Guarde en un lugar seguro sus dos claves de acceso que se le mostrarán. No podrá recuperarlas, serán usadas en secciones posteriores.
16. Dé clic en *Listo*.

Configuración y Creación de Amazon Elastic Container Registry (ECR)

Se debe crear un repositorio de contenedores para almacenar la imagen de la Lambda, esto puede hacerse desde la consola de AWS o mediante AWS CLI siguiendo los pasos descritos en las secciones subsecuentes.

Autenticación en Amazon ECR

Se debe ingresar el siguiente comando para obtener las credenciales que serán necesarias para realizar las configuraciones correspondientes en el servicio de Amazon ECR.

```
aws ecr get-login-password --region us-east-2 | docker login --username AWS --password-stdin <accountID>.dkr.ecr.us-east-2.amazonaws.com
```

Configuración del Repositorio en AWS Elastic Container Registry (ECR)

Una vez que ha sido conseguida una autenticación exitosa, puede procederse a la creación del repositorio donde se almacenará la imagen correspondiente a la función Lambda, debe usarse el siguiente comando para tal propósito.

```
aws ecr create-repository --repository-name ai-vel-repo --region us-east-2
```

El nombre del repositorio debe ser consistente con el flujo de despliegue. En este caso, el repositorio se denomina *ai-vel-repo*.

Despliegue del Sistema RAT en Infraestructura de Amazon Web Services

Documentación sobre los Servicios Utilizados

Amazon Elastic Compute Cloud (EC2)

Servicio de AWS que proporciona capacidad de cómputo en la nube mediante servidores virtuales escalables (conocidos como *instancias*). A diferencia de las arquitecturas *Serverless* (como *Lambda*), *EC2* otorga control total sobre el sistema operativo, permitiendo configurar la memoria, el almacenamiento, las redes y la seguridad a la medida de las necesidades del usuario. Actúa como el servidor o infraestructura permanente (IaaS) donde reside la aplicación. Se utiliza para alojar servicios que requieren ejecución continua, es el servicio que se encarga de alojar el *Backend* del sistema, recibir y procesar las peticiones realizadas desde el *Frontend*.

Nginx

Es un servidor web de alto rendimiento, código abierto y muy ligero, que también funciona como proxy inverso, balanceador de carga y caché HTTP. Está diseñado para manejar miles de conexiones simultáneas con un consumo mínimo de memoria. Se dentro de la instancia de *EC2* para actuar como *Proxy Inverso*. Su función es recibir las peticiones *HTTPS* que llegan desde el *FrontEnd* y redirigirlas de forma interna y segura hacia la aplicación. También se encarga de gestionar los certificados *SSL* (cifrado *HTTPS*) y de servir archivos estáticos (imágenes, CSS, JS) de forma muy eficiente.

Vercel

Es una plataforma en la nube optimizada para el despliegue de aplicaciones web *Frontend* (como *React*, *Next.js*, *Vue*, o *HTML/CSS* estático) y funciones *Serverless* en el *Edge* (redes de distribución global). Destaca por su integración directa con repositorios de *Git* y su modelo de despliegue continuo (*CD*). Se utiliza para alojar y desplegar de manera automatizada la interfaz de usuario, es decir el *Frontend* de la aplicación. Cada vez que se realiza un cambio en el código del *Frontend*, *Vercel* lo compila y lo distribuye globalmente en cuestión de segundos, interactuando con los servicios de *AWS* (*EC2/Lambda*) mediante *APIs* de forma totalmente independiente.

Certbot

Herramienta de software libre y de código abierto desarrollada por la Electronic Frontier Foundation (EFF). Su función principal es automatizar la obtención, instalación y renovación de certificados de seguridad *SSL*.

Se utilizó para realizar la migración segura del protocolo HTTP (no cifrado) al protocolo HTTPS (cifrado). *Certbot* se conecta directamente con el servidor web (*Nginx*) para validar el identificador del dominio, generar las llaves criptográficas necesarias y configurar de forma automática el tráfico seguro.

Configuración de la EC2

Creación de la Instancia EC2

1. Acceda a la consola de *AWS* mediante la cuenta que creo en la sección de *Configuraciones Previas*.
2. Ingrese al servicio de *EC2*. Entrará a una sección de *Introducción*, dé clic en *Lanzar sin ningún tutorial*.
3. Realice las siguientes configuraciones.
 - a. Nombre de la instancia: *RAT-backend*.
 - b. Sistema operativo: *Ubuntu Server 22.04 LTS*.
 - c. Tipo de instancia: *t3.micro*.
 - d. Configuración del par de claves para inicio de sesión.
 - i. Seleccione la opción *Crear un nuevo par de claves*.

- ii. Nombre: *RAT-backend-keys*.
 - iii. Tipo de par de claves: *RSA*.
 - iv. Formato de archivo de clave privada: *pem*.
 - v. Dé clic en la opción *Crear par de claves*.
 - vi. Guarde su par de claves en un lugar seguro, las usará posteriormente.
- e. Almacenamiento: 16 GB
- f. Creación del grupo de seguridad.
 - i. Diríjase a la sección *Configuraciones de red* y seleccione *Crear un grupo de seguridad*.
 - ii. Verifique que se encuentran marcadas las siguientes reglas y con la opción *Mi IP* en lugar de *Cualquier lugar* si aplica.
 - 1. *Permitir el tráfico MSSQL*.
 - 2. *Permitir el tráfico SSH*.
 - 3. *Permitir el tráfico HTTPS desde internet*.
 - 4. *Permitir el tráfico HTTP desde internet*.
 - iii. Presione el botón *Editar* que se encuentra en la parte superior de la tarjeta de *Configuraciones de red* y establezca las siguientes configuraciones.
 - 1. Nombre del grupo de seguridad: *network-security-RAT*.
 - 2. Descripción: únicamente reemplace la porción *launch-wizard-1* por *network-security-RAT*.
 - 3. Mantenga intacta la configuración restante.
- g. Presione el botón *Lanzar instancia* dentro de la sección *Resumen* del lado derecho.

Conexión por SSH a la Instancia EC2

1. Una vez que ha sido creada la instancia, seleccione la opción *Conectarse a la instancia*.
2. Diríjase al apartado *Cliente SSH*.
3. Siga las instrucciones de AWS para conectarse a la nueva instancia EC2 por SSH desde su computadora.

Configuración de un Nombre de Dominio para la Conexión con la EC2 mediante DNS

1. Dar clic [aquí](#), diríjase al apartado superior derecho y dar clic en el botón verde *Sign Up*.
2. Crear una cuenta con usuario y contraseña y posteriormente dar clic en el botón *Free Sign Up* o seleccionar uno de los inicios de sesión con *Google* o *Microsoft*.
3. Una vez creada la sesión se mostrará el panel principal de la página, diríjase al menú lateral izquierdo y dar clic en *DDNS & Remote Access*, se desplegarán opciones debajo, dar clic en *DNS Records*.

4. Una vez abierto el apartado *DNS Records*, dar clic en el botón verde *Create Hostname*.
5. Se mostrarán opciones de configuración, configurar el nombre de host (se recomienda colocar *rat-system*), en el apartado de la derecha al *Host* se configura el tipo de dominio, dar clic y seleccionar *ddns.net*. Para terminar la configuración se debe colocar la IPv4 pública de la EC2 configurada en la sección *Configuración de la EC2*.
6. Dar clic en *create* y esperar a que el dominio acabe de configurarse

Configuración del Sistema RAT dentro de la EC2

Los siguientes pasos deben ejecutarse una vez que ha logrado establecerse la conexión a la EC2 por SSH.

Configuración de Ubuntu

1. Ejecute el siguiente comando para actualizar Ubuntu:
`sudo apt update && sudo apt upgrade -y`
2. Instale las utilidades base:
`sudo apt install -y unzip git curl software-properties-common`
3. Instalación de *Nginx*, *PHP-FPM* y extensiones comunes.
 - a. Instala *Nginx*.
`sudo apt install -y nginx`
 - b. Instala *PHP* y *PHP-FPM*.
 - c. Verifica las versiones de lo instalado con el siguiente par de comandos.
`php -v`
`nginx -v`
4. Verificación del *socket PHP-FPM*.
 - a. Ejecute el siguiente comando.
`ls /run/php/`
 - b. Debería ver algo como *php8.3-fpm.sock*; guarde ese nombre, será usado en *Nginx*.
5. Verifique que *nginx* está activo con el siguiente comando.
`sudo systemctl status nginx`
 - a. Debería ver la sentencia *active (running)*.
 - b. Salga de la vista presionando la tecla *q*.

Instalación de Composer

Ejecute los siguientes comandos.

1. `cd /tmp`
2. `php -r "copy('https://getcomposer.org/installer', 'composer-setup.php');"`

3. `php composer-setup.php`
4. `sudo mv composer.phar /usr/local/bin/composer`
5. `composer --version`

Clonación del Backend desde Github

1. Construya una ubicación estándar.
 - a. `sudo mkdir -p /var/www`
 - b. `sudo chown -R ubuntu:ubuntu /var/www`
 - c. `cd /var/www`
2. Clone únicamente la carpeta de *backend* del repositorio en *Github*.
 - a. `git clone --filter=blob:none --no-checkout https://github.com/V-Alonzo/AI-Collision-Speed-Estimation.git`
 - b. `cd AI-Collision-Speed-Estimation`
 - c. `git sparse-checkout init --cone`
 - d. `git sparse-checkout set RAT-System/CoreSystem/BackEnd`
 - e. `git checkout main`

Instalar Dependencias con Composer

1. Diríjase a `/var/www/AI-Collision-Speed-Estimation/RAT-System/CoreSystem/BackEnd/web`
`cd /var/www/AI-Collision-Speed-Estimation/RAT-System/CoreSystem/BackEnd/web`
2. Actualice *Composer*.
`composer update`
3. Instale las dependencias con *Composer*.
`composer install --no-dev --optimize-autoloader`

Creación del Archivo .env

1. Diríjase a `cd RAT-System/CoreSystem/BackEnd/web/`
2. Copié el archivo base `.env.example` para su `.env`
`cp .env.example .env`
3. Conforme avance en esta guía, completará cada uno de los apartados del archivo `.env`

Permisos de Carpetas

1. Asigne el proyecto al usuario de Nginx/PHP.
`sudo chown -R www-data:www-data /var/www/AI-Collision-Speed-Estimation/RAT-System/CoreSystem/BackEnd`
2. Asigne los siguientes permisos.
 - a. `sudo find /var/www/AI-Collision-Speed-Estimation/RAT-System/CoreSystem/BackEnd -type d -exec chmod 755 {} \;`
 - b. `sudo find /var/www/AI-Collision-Speed-Estimation/RAT-System/CoreSystem/BackEnd -type f -exec chmod 644 {} \;`

Configuración de Nginx

1. Creación del archivo de configuración de Nginx.
`sudo nano /etc/nginx/sites-available/backend`
2. En el proyecto clonado de Github, dirígase a la siguiente ruta *RAT-System/nginx-configuration.txt*; identifique la línea `fastcgi_pass unix:/run/php/php8.3-fpm.sock`; y reemplace el nombre `php8.3-fpm.sock` por el nombre del socket que identificó en pasos anteriores.
3. Copie todo el contenido del archivo y péguelo en su terminal con SSH, guarde el archivo en la EC2 y salga del entorno de *nano*.
4. Desactiva el sitio *default* de Nginx.
`sudo rm -f /etc/nginx/sites-enabled/default`
5. Activación de la configuración.
 - a. Crear el symlink.
`sudo ln -s /etc/nginx/sites-available/backend /etc/nginx/sites-enabled/backend`
6. Revisa el estado de la configuración con el siguiente comando.
`sudo nginx -t`
 - a. Deberá visualizarse una salida como la siguiente:
`nginx: the configuration file /etc/nginx/nginx.conf syntax is ok`
`nginx: configuration file /etc/nginx/nginx.conf test is successful`
7. Reiniciar Nginx y PHP-FPM.
`sudo systemctl restart nginx`
`sudo systemctl restart php*-fpm`
8. Verifica el estado de Nginx.
`sudo systemctl status nginx`
 - a. Deberás visualizar: *active (running)*
9. Activa el sitio.
`sudo ln -s /etc/nginx/sites-available/backend /etc/nginx/sites-enabled/backend`

Prueba Local desde la EC2

1. En una computadora local donde haya clonado todo el proyecto de *Github*, dirígase a la siguiente ruta.
`cd RAT-System/CoreSystem/FrontEnd`
2. Ingrese al archivo `.env` y coloque lo siguiente para el campo `VITE_API_URL`
`http://<IP_PUBLICA_EC2>`
3. Ejecute el *Frontend* con el comando.
`npm run dev`
4. Abra el enlace de Localhost y use el sistema con normalidad, está ejecutando el backend montado en la EC2.

Configuración de HTTPS con Certbot

1. Instalación de Certbot.

- a. `sudo apt update`
 - b. `sudo apt install -y certbot python3-certbot-nginx`
2. Configura nginx con el dominio en Certbot.


```
sudo certbot --nginx -d <dominio_creado_EC2>
```

 - a. Cuando se te solicite ingresar una dirección de correo electrónico, coloca una disponible y de confianza.
 - b. Acepta los términos de servicio.
3. Valida con los siguientes comandos y recarga nginx.
 - a. `sudo nginx -t`
 - b. `sudo systemctl reload nginx`

Configuración de Vercel para el Despliegue del Frontend

Creación de una cuenta en Vercel

1. Dar clic [aquí](#), posteriormente en la parte superior derecha da clic en *Sign Up*.
2. Se mostrará una ventana de elección del tipo de plan, da clic en *I'm working on personal projects* y en el apartado *Your Name* ingresa nombre de la cuenta de GitHub en la que se tiene el repositorio y da clic en *Continue*.
3. Se desplegará una página que solicitará la elección de un proveedor de Git, selecciona GitHub, esto pedirá iniciar sesión en GitHub, iniciar sesión con el usuario y contraseña.
4. La página solicitará permisos para Vercel acerca de tu cuenta de GitHub y algunos más, dar clic en *Authorize Vercel*.

Despliegue del Frontend en Vercel

1. Da clic [aquí](#), si no es iniciada la cuenta creada en la sección *Creación de una cuenta en Vercel* e iniciar sesión con esta cuenta.
2. Dar clic en el botón *Add New* y seleccionar *Project*.
3. En la sección *Import Git Repository* dar clic en *Install*
4. En la ventana emergente deslizar hacia abajo y dar clic en el botón verde *Install*.
5. Una vez instalado Git se mostrará el repositorio de GitHub, dar clic en el botón blanco *Import*.
6. Ahora se mostrará una nueva ventana en la que se harán configuraciones para el despliegue del FrontEnd del sistema, sigue lo siguiente.
 - a. En el apartado *Framework Preset* seleccionar la opción *Vite*.
 - b. En el apartado *Root Directory* da clic en *Edit* y selecciona la carpeta *RAT-System/CoreSystem/FrontEnd* y da clic en *Continue*.
 - c. Ahora dar clic en el botón blanco de la parte inferior *Deploy* y esperar a que el proceso de despliegue termine.
7. Dirigirse al apartado *Environment Variables* y configurar las variables de entorno en base al archivo *env.example*.
8. Dar clic en *Redeploy* y esperar a que el despliegue termine.

Despliegue de Modelos en Amazon Web Services

La presente guía de despliegue tiene como propósito el mostrar una secuencia de pasos que permita desplegar en la nube un conjunto de modelos de Inteligencia Artificial cuya infraestructura y cómputo se encuentre alojada en la suite de Amazon Web Services (AWS).

Documentación sobre los Servicios Utilizados

Docker

Es una tecnología de código abierto basada en contenedores que permite a los desarrolladores empaquetar aplicaciones con todas las partes que necesita como bibliotecas y otras dependencias para distribuir las como un solo paquete.

Se utiliza en la fase de desarrollo local para empaquetar los modelos de IA de la aplicación, garantizando que el software funcione de manera idéntica en cualquier entorno (computadora del desarrollador, entorno de pruebas o en la nube), evitando problemas de versiones o ejecuciones locales.

Amazon Elastic Container Registry

Es un registro de contenedores de Docker totalmente administrado por AWS que facilita a los desarrolladores el almacenamiento, la gestión y el despliegue de imágenes de contenedores de Docker de forma segura y escalable.

Actúa como un almacén privado en la nube. Una vez que se construye localmente la imagen de Docker de los modelos, se carga a Amazon ECR. Desde aquí, otros servicios de AWS podrán descargar la imagen de forma segura para ejecutarla.

Amazon Lambda

Es un servicio informático sin servidor (Serverless) proporcionado por AWS. Permite ejecutar código en respuesta a eventos sin necesidad de aprovisionar ni administrar servidores físicos o virtuales. AWS escala la aplicación de forma automática y solo cobra por el tiempo de cómputo utilizado.

Es el núcleo de ejecución de los modelos de IA. Se configura Amazon Lambda para que extraiga la imagen de Docker almacenada en Amazon ECR y ejecute los modelos de IA para realizar las predicciones cada vez que se dispare un evento específico.

Amazon S3

Es un servicio de almacenamiento de objetos en la nube que ofrece escalabilidad, disponibilidad de datos, seguridad y rendimiento líderes en la industria. Permite guardar cualquier volumen de datos (archivos, imágenes, respaldos, etc.).

Cumple una doble función:

- En esta tecnología se almacenan los archivos de configuración de pesos (.pth) de ambos modelos de IA, el predictivo por imágenes y el híbrido.
- Almacena la imagen requerida por ambos modelos de IA para realizar las inferencias y posterior a su ejecución, son eliminadas.

Despliegue de los Modelos

IMPORTANTE: Ambos modelos comparten gran parte de los servicios previamente configurados en AWS, tales como el repositorio creado en *Amazon Elastic Container Registry* y el *bucket* en *Amazon S3*. Por lo tanto, la configuración entre los modelos es compartida, sin embargo, deben ser cabalmente respetados los siguientes criterios.

- Si va a desplegarse el modelo basado en visión computacional.
 - Para toda etiqueta `<version_number>` que sea encontrada en los comandos, colocar un valor como 1.0, 1.1, 2.0, etc.
 - Para la creación de la función lambda, el nombre debe ser *ai-vel-repo*.
- Si va a desplegarse el modelo dual.
 - Para toda etiqueta `<version_number>` que sea encontrada en los comandos, colocar un valor como 1.0, 1.1, 2.0, etc. Y terminar con `_hyb`
 - Para la creación de la función lambda, el nombre debe ser *ai-vel-repo-hyb*.

Configuración de la Imagen en Docker

Construcción de la Imagen en Docker

La imagen debe construirse explícitamente para la arquitectura linux/amd64. Por otro lado, se recomienda deshabilitar *provenance* y forzar una reconstrucción limpia de tal modo que se eviten inconsistencias derivadas del caché de construcción.

1. Colocarse en la ubicación del archivo Docker con el comando:
`cd "model/src/ImageVelocityEstimator/Deployment/"` si está desplegando el modelo basado en vision computacional, o bien, `"model/src/HybridVelocityEstimator/Deployment"` si se trata del modelo híbrido.
2. Crear la imagen de Docker con el comando:
`docker buildx build --platform linux/amd64 --provenance=false --no-cache -t <accountID>.dkr.ecr.us-east-2.amazonaws.com/ai-vel-repo:v<version_number> .`

Importancia del Etiquetado para la Versión de la Imagen

Se recomienda que cada cambio realizado cuente con un número de versión único y secuencial. De esta manera, se asegura una completa trazabilidad sobre cada uno de los cambios que son realizados en la imagen del contenedor, logrando consecuentemente un eficaz reconocimiento de aquello que está siendo ejecutado por los diferentes servicios de AWS en todo momento. Este valor puede ser reconocido mediante la etiqueta `<VERSION_NUMBER>` que aparece en los diferentes comandos.

Publicación de la Imagen de Docker en Amazon ECR

Una vez construida la imagen, debe enviarse al repositorio ECR mediante el siguiente comando:

```
docker push <accountID>.dkr.ecr.us-east-2.amazonaws.com/ai-vel-repo:v<version_number>
```

Creación de la Función Lambda a partir de la Imagen

Creación de la función Lambda

1. Para crear la función Lambda a partir de la imagen de Docker, debe ejecutarse el siguiente comando.

```
aws lambda create-function --function-name ai-vel-repo --package-type Image --code ImageUri=<accountID>.dkr.ecr.us-east-2.amazonaws.com/ai-vel-repo:v<version_number> --role <IAM_ROLE_ARN> --region us-east-2
```

2. Presione la tecla “q” tras haber creado la función lambda.
3. Revisar que la lambda se haya creado exitosamente con los siguientes pasos:
 - a. Ejecutar el siguiente comando: *aws lambda get-function --function-name ai-vel-repo --region us-east-2*
 - b. Confirmar que la salida es un JSON que contiene la información de la función.
 - c. Ejecuta el siguiente comando y espera a su finalización.
aws lambda wait function-updated --function-name ai-vel-repo --region us-east-2

4. Incrementar el timeout de la función.

```
aws lambda update-function-configuration --function-name ai-vel-repo --region us-east-2 --timeout 120 --memory-size 2048
```

5. Esperar unos segundos y validar la nueva configuración con el siguiente comando.
aws lambda get-function-configuration --function-name ai-vel-repo --region us-east-2 --query '{Timeout:Timeout,MemorySize:MemorySize,LastUpdateStatus:LastUpdateStatus}'

Actualización del Código de la Función

Es importante hacer del conocimiento que la sucesión de comandos inferior debe ejecutarse toda vez que se realizan cambios en la imagen del contenedor. En caso contrario, puede ocurrir que se tenga un despliegue adecuado en ECR, pero la ejecución de una versión desactualizada por Lambda. Dicho de otro modo, el siguiente comando deberá ejecutarse siempre que se realicen cambios en el código de la función lambda que puede ser encontrado en la ruta *model/src/ImageVelocityEstimator/Deployment/orchestator.py* o se realice cualquier alteración en la imagen alojada en Amazon ECR.

Para los siguientes comandos, considere ingresar una tag estrictamente superior a la última utilizada para el valor *<version_number>*.

1. Ejecute los siguientes comandos
 - a. `docker buildx build --platform linux/amd64 --provenance=false --sbom=false --no-cache --load -t <accountID>.dkr.ecr.us-east-2.amazonaws.com/ai-vel-repo:v<version_number> .`
 - b. `docker push <accountID>.dkr.ecr.us-east-2.amazonaws.com/ai-vel-repo:v<version_number>`
2. Actualice la lambda.
`aws lambda update-function-code --function-name ai-vel-repo --image-uri <accountID>.dkr.ecr.us-east-2.amazonaws.com/ai-vel-repo:v<version_id> --region us-east-2`
3. Presione la tecla “q” en caso de observar el despliegue de un JSON.
4. Ejecuta el siguiente comando y espera a su finalización.
`aws lambda wait function-updated --function-name ai-vel-repo --region us-east-2`

Creación y Configuración de la API Gateway para la Función Lambda

Creación de la API

Los pasos generales para la creación de la *API Gateway* como desencadenante de la función *lambda* en *AWS* son:

1. Iniciar sesión en la página de internet que permite el acceso a la consola de *AWS*. Las credenciales deben ser las mismas que las que han sido utilizadas durante todo el procedimiento de esta guía.
2. Dirigirse al servicio *Lambda* para posteriormente seleccionar la función *lambda* recientemente creada bajo el nombre *ai-vel-repo* o *ai-vel-repo.hyb*.
3. Seleccionar la opción que permite agregar un nuevo desencadenador. Establecer el origen del desencadenador al valor *API Gateway*.
4. Seleccionar la opción que indica la creación de una nueva *API*, siendo su tipo: *REST API*
5. Establecer *open* para la configuración de seguridad.
6. Agregar la nueva *Gateway API* mediante el botón con la etiqueta *Agregar*.

Habilitación de CORS

Debido a que el frontend se ejecuta en un origen distinto al de la API como lo puede ser *localhost:3000* en ambientes de desarrollo, es necesario habilitar CORS.

Configuración para CORS en la API Gateway

1. Iniciar sesión en la página de internet que permite el acceso a la consola de *AWS*. Las credenciales deben ser las mismas que las que han sido utilizadas durante todo el procedimiento.
2. Dirigirse al servicio *API Gateway* para después seleccionar la API recientemente creada bajo el nombre *ai-vel-repo-API*.
3. Seleccionar la opción *Habilitar CORS*.

4. Marcar las opciones *Default 4XX* y *Default 5XX*.
5. Guardar la configuración.

Después de habilitar *CORS* en API Gateway, es obligatorio volver a desplegar la API mediante el botón *Implementar API*. En caso contrario, los cambios no se aplicarán al *endpoint* publicado.

Prueba de Funcionamiento sin Cliente Web

Invocación Especial sin Imagen

Bajo el propósito de determinar si un primer despliegue ha sido exitoso y existe comunicación entre todos los servicios previamente configurados de *AWS* y la *CLI*, puede ejecutarse el siguiente comando que creará un archivo *response.json* en *model/src/ImageVelocityEstimator/Deployment/* con el contenido `{"statusCode": 200, "body": "{\"message\": \"OK\"}"}`. Cualquier valor distinto debe considerarse como un error.

```
aws lambda invoke --function-name ai-vel-repo --region us-east-2 --cli-binary-format raw-in-base64-out --payload '{"test":"test"}' response.json
```

Invocación con Imagen

Carga de una Imagen de Ejemplo en S3

De tal manera que pueda ser efectuada una inferencia directamente con el modelo desplegado, primero debe realizarse la carga de una imagen dentro de la instancia de *S3*, la cual será tomada para corroborar la funcionalidad completa. Deben seguirse los siguientes pasos para llevar a cabo este objetivo.

1. Acceder a la consola de *AWS* y al servicio *S3*.
2. Abrir el *bucket ai-vel-bucket*.
3. Abrir la carpeta *Images*.
4. Seleccionar la opción *Cargar*; posteriormente *Agregar Archivos*.
5. En el proyecto clonado desde Github, dirigirse a *model/src/ImageVelocityEstimator/Deployment/ExampleImages* y seleccionar la única imagen disponible. Dejar el resto de las configuraciones predeterminadas y dar clic en *Cargar*. Finalmente, en *Cerrar*.
6. Una vez realizada la carga de la imagen, dar clic sobre ella en el *bucket S3* y luego en *Copiar URI de S3*, guardar este valor.

Invocación de la Función Lambda con la Imagen de Ejemplo en S3 en la AWS CLI

En la consola *AWS CLI*, efectuar el siguiente comando habiendo realizado los pasos descritos en *Carga de una Imagen de Ejemplo en S3*.

Para ambos casos, el comportamiento esperado será la creación de un *JSON* en *model/src/ImageVelocityEstimator/Deployment/response.json* con una configuración de

parámetros cercana o equivalente a `{"velocity_kph": 47.081146240234375}`. Además, la imagen habrá sido automáticamente eliminada del *bucket* en *S3*.

Modelo de Inteligencia Artificial Basado en Visión Computacional

Comando que debe ser ejecutado para recibir la inferencia:

```
aws lambda invoke --function-name ai-vel-repo-hyb --region us-east-2 --cli-binary-format raw-in-base64-out --payload '{"ImageURL": "https://ai-vel-bucket.s3.us-east-2.amazonaws.com/Images/43-kmph-27-mph_4-Severe_019_Vehicle4_AIVELTEST.jpg"}' response.json
```

Modelo Híbrido

Comando que debe ser ejecutado para recibir la inferencia:

```
aws lambda invoke --function-name ai-vel-repo-hyb --region us-east-2 --cli-binary-format raw-in-base64-out --payload '{"ImageURL": "https://ai-vel-bucket.s3.us-east-2.amazonaws.com/Images/ciren_11_52-kmph-32-mph_4-Severe_001_Vehicle1_AIVELTEST.jpeg", "mais": "4 - Severe", "forceDirection": "350 degrees", "rolloverStatus": "No rollover (no overturning)", "damagePlaneDescription": "Front", "severityDescription": "Severe", "vehicleClass": "Intermediate (wheelbase >=265 but < 278 cm)", "curbWeightKg": 1340, "cargoWeightKg": 0}' response.json
```

Invocación de la Función Lambda con la Imagen de Ejemplo en *S3* en la *API Gateway*

La *URL* base que se proporciona para ambos modelos es la que resultó de llevar a cabo los pasos de esta guía por parte de sus autores y puede ser diferente a la obtenida. Para conseguirla, lleve a cabo los siguientes pasos:

1. Diríjase a la consola de *AWS* y acceda con las credenciales que ha utilizado durante todo el procedimiento.
2. Ingrese al servicio *Lambda* y seleccione la función con nombre *ai-vel-repo* o *ai-vel-repo-hyb*.
3. Seleccione el apartado *Configuración*. Una vez que haya ingresado, observará listado su desencadenador *API Gateway* con una característica denominada *Punto de enlace de API*, esta es su *URL* base.

Modelo de Inteligencia Artificial Basado en Visión Computacional

Utilice el cliente *HTTP* de su preferencia para efectuar la siguiente llamada a la *API*.

Los detalles de la llamada se muestran a continuación. No olvide colocar su *URL* base que acaba de obtener en lugar de la que se muestra como ejemplo.

URL base de la *API*: <https://leil6c6oz3.execute-api.us-east-2.amazonaws.com/default/ai-vel-repo>

Parámetros:

- ImageURL: https://ai-vel-bucket.s3.us-east-2.amazonaws.com/Images/43-kmph-27-mph_4-Severe_019_Vehicle4_AIVELTEST.jpg

Llamada con parámetros incorporados:

https://leil6c6oz3.execute-api.us-east-2.amazonaws.com/default/ai-vel-repo?ImageURL=https://ai-vel-bucket.s3.us-east-2.amazonaws.com/Images/43-kmph-27-mph_4-Severe_019_Vehicle4_AIVELTEST.jpg

Modelo de Inteligencia Artificial Híbrido

Utilice el cliente HTTP de su preferencia para efectuar la siguiente llamada a la API.

Los detalles de la llamada se muestran a continuación. No olvide colocar su URL base que acaba de obtener en lugar de la que se muestra como ejemplo.

URL base de la API: <https://a8pd3bep2l.execute-api.us-east-2.amazonaws.com/default/ai-vel-repo-hyb>

Parámetros

- mais: "4 - Severe",
- forceDirection: "350 degrees",
- rolloverStatus: "No rollover (no overturning)",
- damagePlaneDescription: "Front",
- severityDescription: "Severe",
- vehicleClass: "Intermediate (wheelbase >=265 but < 278 cm)",
- curbWeightKg: 1495,
- cargoWeightKg: 0
- ImageURL: https://ai-vel-bucket.s3.us-east-2.amazonaws.com/Images/43-kmph-27-mph_4-Severe_019_Vehicle4_AIVELTEST.jpg

Llamada con parámetros incorporados:

[https://a8pd3bep2l.execute-api.us-east-2.amazonaws.com/default/ai-vel-repo-hyb?mais=4 - Severe&forceDirection=350 degrees&rolloverStatus=No rollover \(no overturning\)&damagePlaneDescription=Front&severityDescription=Severe&vehicleClass=Intermediate \(wheelbase >=265 but < 278 cm\)&curbWeightKg=1495&cargoWeightKg=0&ImageURL=https://ai-vel-bucket.s3.us-east-2.amazonaws.com/Images/43-kmph-27-mph_4-Severe_019_Vehicle4_AIVELTEST.jpg](https://a8pd3bep2l.execute-api.us-east-2.amazonaws.com/default/ai-vel-repo-hyb?mais=4 - Severe&forceDirection=350 degrees&rolloverStatus=No rollover (no overturning)&damagePlaneDescription=Front&severityDescription=Severe&vehicleClass=Intermediate (wheelbase >=265 but < 278 cm)&curbWeightKg=1495&cargoWeightKg=0&ImageURL=https://ai-vel-bucket.s3.us-east-2.amazonaws.com/Images/43-kmph-27-mph_4-Severe_019_Vehicle4_AIVELTEST.jpg)

Invocación de la Función Lambda con la Imagen de Ejemplo en S3 en el Sistema RAT

Para acceder a esta funcionalidad, únicamente deberá crear un archivo `.env` a partir de la información contenida en `RAT-System/CoreSystem/FrontEnd/.env.example`, rellenando cada apartado con elementos que ha recolectado a lo largo de esta guía.