
Estimación de la Velocidad Vehicular Precolisión mediante Aprendizaje Profundo Multimodal Integrando Evidencia Visual Postcolisión y Datos Estructurados de Reconstrucción de Accidentes

Alberto Isaac Sánchez Tarango¹, Alyson Melissa Sánchez Serratos¹, Máximo Moises Zamudio Chávez¹, Miguel Ángel Pérez Ávila¹, Santiago Albarrán Organista¹ y Víctor Alonzo Estévez Chávez¹

¹*Tecnológico de Monterrey, Escuela de Ingeniería y Ciencias, Campus Toluca, Estado de México, México*

Fecha de recepción: dd/mm/aaaa

Fecha de aceptación: dd/mm/aaaa

Fecha de publicación: dd/mm/aaaa

Resumen— La estimación de la velocidad vehicular precolisión constituye un problema de interés en la reconstrucción forense de accidentes debido a su relevancia para el análisis de la dinámica del impacto. En este trabajo se propone una arquitectura de aprendizaje profundo multimodal que integra evidencia visual postcolisión y datos estructurados de reconstrucción de accidentes provenientes del programa Crash Injury Research and Engineering Network (CIREN). La metodología combina representaciones visuales extraídas mediante redes neuronales convolucionales con variables técnicas del siniestro dentro de un esquema unificado de regresión. Los resultados experimentales muestran que el enfoque propuesto supera el desempeño de modelos unimodales basados exclusivamente en imágenes o datos tabulares, alcanzando una precisión aproximada de ± 4.5 km/h. La mayor reducción del error se observó en el intervalo de 0–60 km/h, mientras que el desempeño en velocidades superiores se vio limitado por el desbalance inherente del conjunto de datos. Los hallazgos obtenidos evidencian el potencial de los enfoques multimodales para apoyar procesos automatizados de reconstrucción forense de accidentes vehiculares.

Palabras clave— velocidad vehicular precolisión, reconstrucción de accidentes, aprendizaje multimodal, daños estructurales vehiculares, redes neuronales convolucionales, transferencia de aprendizaje, datos estructurados.

I. INTRODUCCIÓN

Los siniestros viales representan una problemática de alcance global con profundas implicaciones económicas, jurídicas y sociales. Según la Organización Mundial de la Salud, los accidentes de tránsito generan pérdidas equivalentes a aproximadamente el 3% del producto interno bruto de la mayoría de los países, considerando costos asociados a atención médica, daños materiales, pérdida de productividad e impacto sobre los sistemas de aseguramiento [1]. Más allá de sus consecuencias económicas directas, estos eventos frecuentemente dan origen a procedimientos administrativos, periciales y judiciales en los que resulta indispensable establecer, de manera objetiva y técnicamente sustentada, las circunstancias bajo las cuales ocurrió la colisión. En este contexto, la reconstrucción técnica del accidente constituye una herramienta fundamental: mediante la aplicación de principios físicos y el análisis sistemático de la evidencia material, permite determinar variables

críticas como trayectorias de movimiento, velocidades de circulación, mecanismos de impacto y grado de contribución de cada uno de los involucrados [2]. Los resultados derivados de estos análisis son empleados como soporte técnico en procesos judiciales, investigaciones de responsabilidad civil y penal, y en la resolución de reclamaciones dentro del sector asegurador, donde la correcta interpretación de los hechos puede tener consecuencias económicas y legales de considerable magnitud [2, 3].

Entre las variables analizadas en los procesos de reconstrucción de accidentes, la estimación de la velocidad vehicular previa al impacto reviste particular relevancia técnica. Dado que la energía cinética es proporcional al cuadrado de la velocidad, incrementos relativamente moderados en esta variable se traducen en aumentos sustanciales de la energía disipada durante la colisión, con efectos directos sobre la magnitud de las deformaciones estructurales, el alcance de los daños materiales y las cargas transmitidas a los ocupantes. La velocidad determina, asimismo, la dinámica general del siniestro: las trayectorias posteriores al impacto, las distancias de desplazamiento y los patrones de interacción entre los vehículos involucrados [3]. Por estas razones, su determinación constituye un

componente central en investigaciones forenses, peritajes técnicos y procesos de evaluación de reclamaciones en el ámbito asegurador [4].

Las metodologías tradicionales para la estimación de velocidad se fundamentan en principios de mecánica clásica, particularmente en el análisis de conservación del momento lineal, modelos de energía de deformación y procedimientos basados en la cuantificación del daño estructural vehicular [3, 5]. Entre los enfoques más consolidados se encuentran los modelos de análisis de deformación desarrollados por McHenry, posteriormente formalizados en metodologías como CRASH3, los cuales estiman la energía absorbida durante la colisión a partir de la deformación residual del vehículo y de parámetros de rigidez estructural específicos para cada configuración vehicular [5, 6]. La implementación de estos métodos requiere la medición precisa de perfiles de aplastamiento, profundidades de deformación y dimensiones geométricas distribuidas a lo largo de las zonas impactadas, información que, en general, solo puede obtenerse mediante inspecciones presenciales y procedimientos especializados de levantamiento pericial. Su precisión depende, además, de la disponibilidad de coeficientes de rigidez adecuados y del acceso directo a las áreas deformadas para verificar la extensión real del daño estructural. En consecuencia, cuando la evidencia física es limitada, ha sido alterada por intervenciones posteriores al accidente, como labores de rescate o remoción de vehículos, o únicamente se dispone de registros fotográficos, la aplicación de estos procedimientos resulta significativamente más compleja y sujeta a mayores niveles de incertidumbre [5, 6].

Esta situación no es excepcional en la práctica pericial; por el contrario, representa una condición recurrente ampliamente documentada en la literatura especializada. Kerkhoff [7] señala que, en la mayoría de los accidentes de transporte terrestre, en el momento en que se solicita una reconstrucción, los únicos datos disponibles consisten en el reporte policial y las fotografías del siniestro. En el mismo sentido, la literatura técnica en el campo de la reconstrucción forense establece que las fotografías constituyen con frecuencia la única evidencia remanente de una colisión, dado que la evidencia de la escena desaparece, los vehículos son reparados o desechados, y los componentes son sometidos a pruebas de falla [8]. Lo anterior pone de manifiesto la necesidad de desarrollar metodologías capaces de extraer información cuantitativa a partir de evidencia visual obtenida después de la colisión.

En paralelo, la creciente digitalización de expedientes periciales y el desarrollo de bases de datos especializadas han ampliado considerablemente la disponibilidad de información asociada a accidentes reales. Entre las más relevantes se encuentra el programa Crash Injury Research and Engineering Network (CIREN), iniciativa de la National Highway Traffic Safety Administration (NHTSA) de los Estados Unidos orientada a la investigación en profundidad de accidentes de alta severidad mediante un enfoque multidisciplinario. Esta base de datos integra imágenes de vehículos siniestrados, información técnica de reconstrucción, registros de daño estructural, variables dinámicas del impacto, datos biomecánicos y antecedentes clínicos de los ocupantes involucrados [9]. Su nivel de detalle y la diversidad de información disponible para cada

caso la consolidan como una de las fuentes más relevantes para la investigación en seguridad vehicular, biomecánica del trauma y reconstrucción de accidentes, al tiempo que crean condiciones favorables para el desarrollo de herramientas automatizadas orientadas al análisis forense.

En este escenario, los avances recientes en aprendizaje profundo han propiciado el desarrollo de sistemas de análisis visual con capacidad de desempeño comparable, y en determinadas tareas superior, al de especialistas humanos en problemas de visión por computadora, reconocimiento de patrones y procesamiento de datos de alta dimensionalidad. En tareas de clasificación visual compleja, se ha documentado que arquitecturas de redes neuronales profundas superan el nivel de precisión alcanzado por expertos humanos [10]. En el dominio automotriz, esta capacidad ha encontrado aplicaciones con resultados cuantitativamente relevantes: modelos basados en redes neuronales convolucionales han demostrado un desempeño equivalente al de peritos especializados en la localización y clasificación de daños estructurales vehiculares [11]; sistemas de segmentación de instancias fundamentados en arquitecturas Mask R-CNN han reportado precisiones superiores al 92% en la cuantificación automatizada de daños en el contexto de reclamaciones aseguradoras [12]; y enfoques de transferencia de aprendizaje aplicados a la clasificación de tipología de daño han alcanzado exactitudes de hasta el 96% sobre conjuntos de validación independientes [13]. Revisiones sistemáticas de la literatura reciente confirman la consolidación de estas metodologías como referente técnico en tareas de inspección automatizada, identificación de componentes afectados y estimación de severidad a partir de evidencia fotográfica [14], lo que pone de manifiesto la capacidad inherente de los modelos profundos para aprender representaciones discriminativas de alto nivel directamente desde los datos, prescindiendo de la ingeniería manual de características.

No obstante, la revisión de la literatura especializada revela que la gran mayoría de los trabajos publicados se ha concentrado en tareas de clasificación, detección y segmentación de daños visibles. Una revisión sistemática reciente que analizó más de 55 estudios confirmó que la distribución de la investigación se concentra predominantemente en tareas de clasificación de daño, seguida por detección en más de 15 trabajos y segmentación en más de 20, sin que ninguno de los estudios analizados abordara la estimación cuantitativa de variables dinámicas asociadas al estado previo al impacto [14]. La estimación de la velocidad vehicular precolisión a partir de evidencia visual postcolisión ha recibido una atención comparativamente marginal en la literatura de aprendizaje profundo. Los escasos trabajos que han explorado esta dirección han operado bajo restricciones significativas: Argote et al. [15] limitaron su estudio a vehículos de pasajeros de tamaño pequeño con colisiones frontales y traseras a velocidades inferiores a 96 km/h, empleando datos de la base CIREN; mientras que aproximaciones basadas en redes neuronales profundas para recuperar condiciones iniciales de impacto a partir del estado de deformación final han sido caracterizadas explícitamente como un problema inverso de alta complejidad, señalando que parámetros críticos como la velocidad tangencial de contacto, la posición del centro de impacto y

las condiciones precisas de la interacción neumático-calzada resultan frecuentemente inasequibles para los métodos convencionales [16]. Paralelamente, trabajos recientes en estimación de velocidad precolisión mediante aprendizaje automático han reconocido de manera explícita que la aplicación de técnicas de aprendizaje en conjunto a este problema constituye un vacío de investigación no explorado hasta la fecha [17]. Esta brecha puede atribuirse, entre otros factores, a la limitada disponibilidad de conjuntos de datos que integren evidencia visual postcolisión con parámetros de reconstrucción técnicamente validados, a la complejidad inherente del problema inverso que supone inferir variables físicas no observables directamente a partir de evidencia obtenida después del evento, y a la alta variabilidad presente en los escenarios reales de colisión en términos de configuraciones estructurales vehiculares, mecanismos de deformación y heterogeneidad de la información disponible [14, 16]. En conjunto, estos factores representan desafíos sustantivos para el desarrollo de modelos con capacidad de generalización robusta en condiciones de operación real.

Frente a este panorama, el presente trabajo tiene como objetivo investigar la viabilidad de estimar la velocidad vehicular precolisión mediante técnicas de aprendizaje profundo, utilizando información proveniente de accidentes reales documentados en la base de datos CIREN. A diferencia de los enfoques tradicionales de reconstrucción, que requieren inspección presencial y medición directa de perfiles de deformación, la estrategia propuesta explora la posibilidad de inferir esta variable dinámica a partir de evidencia observacional disponible después del siniestro, específicamente a partir de la combinación de registros fotográficos del daño estructural vehicular y variables técnicas de caracterización del accidente en formato tabular. Esta integración de fuentes heterogéneas de información constituye el núcleo de un enfoque multimodal, en el cual los patrones visuales capturados por redes neuronales convolucionales y las relaciones estructuradas entre variables numéricas y categóricas procesadas por modelos de aprendizaje profundo son fusionados para producir una estimación continua de la velocidad de impacto. La hipótesis subyacente es que la deformación estructural residual visible en las imágenes postcolisión, combinada con información contextual del siniestro, contiene información suficiente para aproximar las condiciones cinéticas previas al impacto sin necesidad de acceso físico directo al vehículo ni de instrumentación especializada de levantamiento pericial.

Con este propósito, se analiza de manera sistemática el aporte individual y conjunto de ambas modalidades de información, evaluando en qué medida la incorporación de evidencia visual enriquece la capacidad predictiva de los modelos respecto al uso exclusivo de variables tabulares, y viceversa. En síntesis, las contribuciones de este estudio son: (i) la sistematización de un proceso reproducible de preparación de datos forenses vehiculares con velocidades técnicamente verificadas, (ii) la construcción de un conjunto de datos curado de siniestros reales orientado a la estimación continua de velocidad precolisión, y (iii) la propuesta y evaluación de una arquitectura de aprendizaje profundo multimodal para la reconstrucción automatizada de la velocidad de impacto a partir de evidencia observacional postcolisión. Estas aportaciones buscan avanzar hacia

metodologías periciales más objetivas, escalables y consistentes, fortaleciendo el papel de la inteligencia artificial como herramienta de apoyo en la reconstrucción forense de accidentes viales.

II. TRABAJO RELACIONADO

La revisión de la literatura en torno a la estimación automatizada de variables dinámicas de colisión mediante técnicas de aprendizaje automático puede organizarse en cuatro líneas de investigación diferenciadas: (i) métodos de reconstrucción de velocidad precolisión basados en datos tabulares estructurados, (ii) métodos de reconstrucción basados en datos de deformación y el problema inverso, (iii) detección y clasificación de daño vehicular mediante aprendizaje profundo a partir de imágenes, y (iv) enfoques multimodales que integran fuentes heterogéneas de información para la predicción de variables relacionadas con accidentes. A continuación se examinan los trabajos más relevantes en cada una de estas líneas, identificando sus contribuciones, limitaciones y su relación con el problema abordado en el presente estudio.

a. Estimación de velocidad precolisión mediante aprendizaje automático con datos tabulares

Los primeros trabajos que introdujeron técnicas de aprendizaje automático en la estimación de velocidad precolisión se fundamentaron en datos tabulares derivados de bases de pruebas de choque controladas, prescindiendo de cualquier componente visual. Cioroianu et al. [18] propusieron la aplicación de un perceptrón multicapa (MLP) entrenado con registros de la base de datos de pruebas frontales de la NHTSA, utilizando como variables de entrada la masa del vehículo, la anchura de la zona de deformación y los coeficientes de deformación C1 a C6, con el objetivo de estimar la Velocidad Equivalente de Energía (EES). El modelo alcanzó un error relativo medio aproximado del 9%, representando una mejora respecto a las regresiones lineales empleadas por las metodologías convencionales como CRASH3. No obstante, el alcance del estudio se restringió explícitamente a colisiones frontales contra barrera rígida en la clase de vehículo intermedio, lo que limita considerablemente su aplicabilidad a escenarios reales de mayor variabilidad.

En esa misma dirección, Czajewski et al. [17] desarrollaron un modelo de regresión basado en bosques aleatorios (Random Forest) para la estimación de velocidad precolisión en vehículos compactos involucrados en impactos frontales de ancho completo contra barrera rígida, empleando 399 registros de la base de datos NHTSA. Los autores compararon el desempeño de su modelo frente a regresión lineal, MLP y métodos de Gradient Boosting, obteniendo resultados superiores en términos de error relativo, y aplicaron valores SHAP para analizar la importancia de las variables. Una contribución relevante del trabajo es el reconocimiento explícito de que la aplicación de técnicas de aprendizaje en conjunto a la estimación de velocidad precolisión constituía, hasta la fecha de su publicación, un vacío de investigación no explorado. Sin embargo, al igual que en el trabajo anterior, el estudio opera exclusivamente

sobre datos tabulares de pruebas controladas, sin incorporar información visual del daño, y su generalización a accidentes reales de campo permanece sin validar.

b. Recuperación de condiciones de impacto mediante el enfoque de problema inverso

Una línea conceptualmente más ambiciosa corresponde a los trabajos que formulan la estimación de parámetros precolisión como un problema inverso, en el que el estado de deformación postcolisión constituye la señal de entrada y las condiciones iniciales del impacto son el objetivo a recuperar. Zhao et al. [16] desarrollaron un marco de aprendizaje profundo basado en redes neuronales densas entrenadas con datos de simulación de elementos finitos generados mediante LS-DYNA, con el fin de recuperar condiciones iniciales de impacto a partir de la distribución de deformación plástica residual de la carrocería vehicular. Los autores demostraron que el algoritmo es capaz de identificar de manera aproximadamente única la velocidad de contacto relativa y el ángulo de impacto a partir del estado final de deformación, constituyendo uno de los primeros trabajos en demostrar la viabilidad del enfoque inverso para reconstrucción forense mediante aprendizaje profundo.

No obstante, este trabajo presenta limitaciones sustanciales que reducen su aplicabilidad directa en contextos periciales reales. En primer lugar, los datos de entrenamiento provienen íntegramente de simulaciones numéricas de elementos finitos, lo que implica que el modelo aprende representaciones de deformación idealizadas que pueden diferir significativamente de los patrones observados en colisiones reales de campo, donde intervienen factores como irregularidades geométricas, condiciones de la calzada, deformaciones secundarias y variabilidad en las propiedades de los materiales. En segundo lugar, la señal de entrada utilizada corresponde a campos de deformación tridimensionales obtenidos de simulación, no a fotografías convencionales del vehículo, lo que hace que la metodología propuesta sea inaplicable directamente cuando la única evidencia disponible es documentación fotográfica postaccidente. El presente trabajo se diferencia fundamentalmente en que opera sobre imágenes fotográficas reales de accidentes de campo documentados en CIREN, prescindiendo de simulación numérica y de medición directa de perfiles de deformación.

c. Estimación de velocidad y características de colisión a partir de imágenes mediante aprendizaje profundo

El trabajo más directamente relacionado con el presente estudio es el de Argote et al. [15], quienes propusieron un enfoque de aprendizaje profundo multiobjetivo para estimar el Delta-V y clasificar la localización de colisión (LOC) a partir de imágenes fotográficas de vehículos siniestrados, utilizando datos de la base CIREN. Empleando arquitecturas CNN con aprendizaje multitarea, los autores reportaron un MAE de 4.19 km/h (MAPE de 16.2%) para la estimación del Delta-V sobre 310 imágenes reales de colisión, y una exactitud del 92% en la clasificación de la localización del impacto. El estudio también desarrolló y refinó

las arquitecturas utilizando imágenes generadas mediante software de simulación de colisiones, logrando un MAE de 3.41 km/h sobre imágenes simuladas. Este trabajo constituye el precedente más cercano al problema abordado en el presente artículo; sin embargo, presenta restricciones importantes: el estudio se limitó a vehículos de pasajeros de tamaño pequeño y a colisiones frontales y traseras con velocidades inferiores a 96 km/h, el tamaño del conjunto de imágenes reales empleado fue reducido (310 imágenes), y no se exploró la integración de información tabular contextual del siniestro como modalidad complementaria a las imágenes.

En el ámbito de la clasificación y segmentación de daños vehiculares a partir de imágenes, la literatura reporta un desarrollo considerable que establece las capacidades de los modelos profundos sobre este tipo de evidencia visual. Patil et al. [13] propusieron un sistema de clasificación de daño basado en CNN con transferencia de aprendizaje desde ImageNet, alcanzando una exactitud del 89.5% sobre categorías de daño relevantes para el procesamiento de reclamaciones aseguradoras. Kyu y Woraratpanya [19] emplearon modelos VGG16 y VGG19 con regularización para detección, localización y estimación de severidad de daño vehicular, reportando exactitudes de 95.2% y 94.6% en detección, 76.5% y 74.4% en localización, y 57.9% y 54.8% en clasificación de severidad, respectivamente, evidenciando que la tarea de severidad resulta significativamente más difícil que la de detección. Jameel et al. [12] extendieron este enfoque mediante una arquitectura Mask R-CNN con Inception ResNetV2 preentrenado, logrando una precisión del 89.13% y una exactitud global del 92% en la localización y clasificación simultánea de la severidad del daño. Van Ruitenbeek y Bhulai [11] desarrollaron un detector de daños vehiculares entrenado sobre más de 10,000 imágenes en 12 categorías de daño para servicios de movilidad compartida, demostrando que el modelo alcanza un desempeño comparable al de expertos del dominio en la evaluación de daños, lo que representa un hito relevante en términos de validación frente a criterio humano especializado.

Estos trabajos establecen colectivamente que los modelos profundos son capaces de extraer información discriminativa de alto nivel a partir de imágenes de daño vehicular. Sin embargo, como señala la revisión sistemática de Hasan et al. [14], ninguno de los más de 55 estudios analizados abordó la estimación cuantitativa de variables dinámicas precolisión, como la velocidad de impacto, confirmando el vacío que el presente trabajo busca abordar.

d. Enfoques multimodales en análisis de accidentes

La integración de múltiples modalidades de información ha emergido como una línea de investigación relevante dentro de la aplicación del aprendizaje profundo al análisis de accidentes de tránsito. Sin embargo, la mayor parte de los trabajos reportados en la literatura se ha concentrado en tareas de clasificación, detección o predicción de severidad, mientras que la estimación de variables físicas asociadas a la reconstrucción del accidente continúa siendo un problema relativamente poco explorado.

Bhowmik y Rateria [20] propusieron una arquitectura

multimodal para detección automática de colisiones que combina información visual proveniente de imágenes con variables tabulares relacionadas con el contexto del accidente. Su enfoque integra una red convolucional VGG16 para el procesamiento de imágenes y una red neuronal recurrente para el análisis de variables estructuradas, utilizando una estrategia de fusión profunda de características. Los autores reportaron un desempeño superior respecto a los modelos unimodales, alcanzando un ROC-AUC de 1.00 sobre el conjunto de prueba frente a los resultados obtenidos utilizando únicamente información visual. Asimismo, identificaron que los modelos basados exclusivamente en datos tabulares presentan dificultades para capturar relaciones complejas asociadas al contexto visual del accidente, mientras que los modelos fundamentados únicamente en imágenes carecen de información contextual suficiente para describir adecuadamente el fenómeno analizado. No obstante, el estudio se limita a una tarea de clasificación binaria de colisiones y no aborda la estimación de variables continuas asociadas a la dinámica del impacto.

De manera complementaria, Liu et al. [21] desarrollaron un marco multimodal para la predicción de severidad de accidentes integrando registros estructurados de siniestros, características geométricas de la infraestructura vial y descripciones textuales de los eventos. Su propuesta incorpora mecanismos de atención adaptativa y arquitecturas tipo Mixture-of-Experts para modelar las contribuciones específicas de cada modalidad. Los resultados obtenidos mostraron un desempeño superior respecto a diversos enfoques tradicionales y redes neuronales convencionales, alcanzando una exactitud de 86.5%, un recall de 86.8% y un F1-score de 0.712. Adicionalmente, el modelo logró tasas de identificación superiores al 94% para las categorías de accidentes más severos, evidenciando una capacidad robusta para el manejo de clases desbalanceadas. Los análisis de ablación demostraron que la incorporación conjunta de mecanismos de atención, expertos especializados e interacciones cruzadas entre modalidades contribuye significativamente al rendimiento global del sistema. Estos hallazgos refuerzan la hipótesis de que la integración de múltiples fuentes de información permite capturar características complementarias del fenómeno estudiado y superar las limitaciones inherentes a los enfoques unimodales. No obstante, al igual que en trabajos previos, el objetivo principal estuvo orientado a la clasificación de severidad y no a la estimación de parámetros físicos asociados a la reconstrucción del accidente.

La relevancia de los enfoques multimodales también ha sido respaldada por evidencia agregada a gran escala. En una revisión sistemática y metaanálisis que analizó 74 estudios y más de 2.1 millones de registros de accidentes, Somvanshi et al. [22] reportaron que los modelos de aprendizaje profundo superan de manera significativa a los métodos convencionales de aprendizaje automático en tareas de predicción relacionadas con accidentes de tránsito, obteniendo una diferencia promedio de 7.7 puntos porcentuales en desempeño. Los autores identificaron además que las arquitecturas híbridas basadas en la combinación de múltiples modalidades alcanzan niveles de desempeño superiores a los modelos unimodales, destacando particularmente los enfoques basados en transferencia de aprendizaje

y arquitecturas híbridas CNN-RNN. Asimismo, concluyen que los enfoques multimodales representan una de las direcciones más prometedoras para investigaciones futuras debido a su capacidad para integrar fuentes de información complementarias y mejorar la capacidad predictiva de los modelos.

El presente trabajo se inscribe precisamente en esta dirección, pero con un objetivo y una variable objetivo cualitativamente distintos: no se trata de clasificar la severidad de las lesiones o detectar la ocurrencia de un accidente, sino de estimar de forma continua la velocidad vehicular precolisión a partir de la fusión de imágenes fotográficas del daño estructural y variables tabulares de caracterización del siniestro, empleando accidentes reales de campo documentados en CIREN con velocidades técnicamente reconstruidas y validadas. Esta combinación de objetivo, tipo de datos, fuente y enfoque multimodal no tiene precedente directo en la literatura revisada, lo que subraya la originalidad y pertinencia de la contribución propuesta.

III. METODOLOGÍA

a. Datos y preprocesamiento

1. Fuente de datos y criterios de construcción de la base de datos utilizada para el entrenamiento de los modelos predictivos de regresión

La serie de componentes que han sido elaborados sobre la base de datos denominada Crash Injury Research Engineering Network (CIREN) y perteneciente al NHTSA Crash Viewer, se orientan a transformar información pública de siniestros vehiculares en una estructura analítica de importante utilidad para tareas de estimación de velocidad preimpacto a partir de evidencia postcolisión. Para ello, se parte de casos documentados con dos tipos de insumo complementario: metadatos del evento y del vehículo involucrado, junto con galerías fotográficas asociadas al daño observado tras la colisión. La lógica metodológica seguida no consiste únicamente en recolectar imágenes, sino en vincular cada fotografía válida con un contexto de siniestro suficientemente caracterizado en términos de severidad, dinámica de impacto y atributos generales del vehículo de tal manera que cada uno de estos elementos multimedia maximicen su valor cualitativo para la explicación del fenómeno físico de impacto y su relación directa con la velocidad a la que ocurrió.

El proceso se diseñó bajo tres principios: trazabilidad, reanudación y utilidad analítica. Primeramente, la trazabilidad garantiza que cada imagen final conserve su vínculo con el caso de origen y con el vehículo al que pertenece. Por otro lado, la reanudación permite continuar ejecuciones incompletas sin repetir el procesamiento ya realizado y, finalmente, la utilidad analítica asegura que el resultado no sea solo una galería visual, sino un conjunto estructurado de ejemplos listos para ser explorados y posteriormente consumidos por los modelos predictivos seleccionados.




Figura 1: Diagrama de flujo general del pipeline para el tratamiento y persistencia de la base de datos de CIREN




Figura 2: Diagrama de flujo que muestra la lógica de consolidación de un caso reportado en CIREN

2. Caracterización del caso y selección del vehículo de interés

Una vez identificado un caso particular desde la base de datos de CIREN, el flujo adquiere la responsabilidad de integrar la información descriptiva disponible para construir una representación compacta del evento. En esta etapa, se priorizan variables con valor directo para interpretación biomecánica y estructural del impacto tal y como lo son la severidad máxima de lesión humana tras el incidente, el cambio total de velocidad, la dirección del impacto, el patrón general de deformación, el plano principal de daño y características generales del vehículo, entre las cuales pueden ser encontradas: clase, masa base y carga reportada. Cada una de estas variables permiten contextualizar visualmente el daño y, al mismo tiempo, aportan atributos cuantitativos y categóricos relevantes para el diseño, preparación y entrenamiento de los modelos de inferencia.

Dado que un mismo caso puede contener múltiples vehículos o varias vistas de interés involucradas, se implementó una etapa de conciliación para identificar al vehículo principal que será estudiado. Esta decisión adquiere especial relevancia al permitir evitar la inadecuada mezcla de imágenes pertenecientes a actores distintos dentro de un mismo siniestro, al igual que mejorar la coherencia entre la evidencia visual y los metadatos asociados. De esta forma, la unidad efectiva de análisis queda definida como el par compuesto por caso y vehículo principal, sobre el cual se organiza el resto del preprocesamiento.

3. Catalogación de imágenes candidatas

La colección fotográfica asociada a cada caso no se incorpora de manera directa a la base de datos final, sino que se lleva a cabo una fase de catalogación cuyo objetivo es reunir todas las vistas potencialmente útiles del vehículo seleccionado y registrar su procedencia. En esta etapa, cada imagen candidata conserva información descriptiva suficiente para identificarla posteriormente, incluyendo su relación con el vehículo, la vista o categoría visual de la que proviene y un identificador estable y estrictamente incremental para evitar la sobrescritura de archivos en tiempo de ejecución.

Metodológicamente, esta fase cumple dos funciones, la primera es separar el descubrimiento de contenido de la validación visual, lo cual reduce reprocesamiento en ejecuciones sucesivas y la segunda es imponer una preselección semántica: se descartan categorías de imágenes que típicamente aportan poco a la reconstrucción del daño estructural como lo pueden ser: tomas irrelevantes que no pertenezcan directamente a los vehículos involucrados, vistas no exteriores del automóvil o material complementario de baja utilidad para análisis forense del vehículo. Consecuentemente, el conjunto candidato se concentra en fotografías con mayor probabilidad de contener evidencia visual de interés.




Figura 3: Diagrama de estados que muestra la transición de una imagen candidata a persistida o descartada

4. Filtrado visual y validación de evidencia dañada

Después de la catalogación, cada candidato se somete a una etapa de validación visual artificial orientada a confirmar que la fotografía contiene evidencia utilizable de daño vehicular. La lógica de esta etapa se centra en evitar que la base de datos final contenga imágenes sin daño apreciable o con contenido visual poco representativo del fenómeno de interés. Dicho de otro modo, no toda imagen asociada a un caso CIREN es útil para modelar severidad de colisión o estimar velocidad preimpacto. Por ello, fue necesario incorporar un filtro automatizado que priorice señales visibles de deformación estructural para reducir la probabilidad de ocurrencia de esta serie de casos innecesarios.




Figura 4: Diagrama de flujo donde se muestra el proceso de validación visual de una imagen extraída de un caso en CIREN

5. Normalización de salidas para análisis posterior

El resultado del preprocesamiento de imágenes y características extraídas desde CIREN es organizado en dos niveles complementarios: caso e imagen. El primero se concentra en la caracterización del siniestro y del vehículo, mientras que el segundo tiene el objetivo de conservar la evidencia visual validada con su referencia al caso correspondiente. Esta separación permite analizar la información desde una perspectiva estadística o computacional sin perder la granularidad particular de cada fotografía.




Figura 5: Diagrama de entidad relación del conjunto resultante del preprocesamiento y extracción de datos de CIREN

b. Diseño Experimental

Con el propósito de analizar la viabilidad de estimar la velocidad vehicular precolisión a partir de información disponible después de un siniestro, se definió un diseño experimental compuesto por tres enfoques complementarios basados en distintas modalidades de datos. Esta estrategia permitió evaluar de manera independiente la contribución de la evidencia visual, la información estructurada y la combinación de ambas fuentes dentro de un mismo marco de predicción.

1. Enfoque basado en imágenes

La primera hipótesis plantea que las deformaciones estructurales observables en imágenes postcolisión contienen información suficiente para inferir la velocidad vehicular precolisión. Bajo este supuesto, se desarrolló un modelo de aprendizaje profundo basado exclusivamente en imágenes, orientado a identificar patrones visuales asociados con distintos niveles de severidad de impacto y utilizarlos para realizar una estimación continua de velocidad.

2. Enfoque basado en variables tabulares

La segunda hipótesis establece que las variables técnicas registradas durante los procesos de reconstrucción de accidentes contienen información predictiva suficiente para estimar la velocidad precolisión sin necesidad de evidencia visual. Para evaluar esta hipótesis se desarrolló un modelo basado exclusivamente en variables tabulares provenientes de la base de datos CIREN, incluyendo características relacionadas con el vehículo, la dinámica del impacto y la descripción estructural del daño.

3. Enfoque multimodal

La tercera hipótesis propone que la integración de evidencia visual e información estructurada permite construir una representación más completa del accidente que cualquiera de las modalidades por separado. Con base en este planteamiento, se diseñó una arquitectura multimodal capaz de combinar simultáneamente características extraídas de imágenes postcolisión y variables tabulares asociadas al siniestro, con el objetivo de determinar si la fusión de ambas fuentes de información mejora la precisión de las estimaciones de velocidad.

La evaluación conjunta de estos tres enfoques permite cuantificar el aporte individual de cada modalidad y analizar el beneficio potencial derivado de su integración dentro de un esquema multimodal de aprendizaje profundo orientado a la reconstrucción forense de accidentes.

c. Modelo Basado en Imágenes

Con el objetivo de evaluar la capacidad predictiva de la evidencia visual disponible después de una colisión vehicular, se formuló la hipótesis de que la velocidad precolisión puede estimarse a partir de las deformaciones estructurales observables en imágenes postimpacto, prescindiendo completamente de variables tabulares o mediciones físicas directas del vehículo. Esta hipótesis se fundamenta en el hecho de que la magnitud y distribución del daño

estructural constituyen una manifestación física de la energía disipada durante la colisión y, por tanto, contienen información indirectamente relacionada con la velocidad del impacto.

Para validar este planteamiento se desarrolló una arquitectura de visión computacional denominada *ImageVelocityEstimator*, diseñada para resolver el problema como una tarea de regresión supervisada. En esta formulación, la entrada del modelo corresponde a una imagen fotográfica de un vehículo involucrado en un accidente, mientras que la salida consiste en una estimación continua de la velocidad precolisión expresada en kilómetros por hora.

1. Arquitectura Propuesta

La arquitectura desarrollada se construyó siguiendo un enfoque de *Transfer Learning*, aprovechando conocimiento previamente adquirido por modelos entrenados sobre grandes volúmenes de datos visuales. Para ello se seleccionó la arquitectura ResNet50 como extractor principal de características, utilizando pesos preentrenados sobre el conjunto de datos ImageNet.

La elección de ResNet50 se fundamentó en tres factores principales. En primer lugar, esta arquitectura ha demostrado un desempeño sobresaliente en tareas de clasificación visual y extracción de características de alto nivel. En segundo lugar, la utilización de conexiones residuales permite entrenar redes profundas mitigando problemas asociados a la desaparición del gradiente. Finalmente, existe amplia evidencia en la literatura que respalda su capacidad para adaptarse exitosamente a dominios especializados mediante procesos de ajuste fino (*Fine-Tuning*).

Dentro de la arquitectura propuesta, ResNet50 actúa como un extractor jerárquico de representaciones visuales. Las primeras capas de la red capturan patrones elementales como bordes, texturas y contornos, mientras que las capas más profundas aprenden estructuras visuales progresivamente más complejas relacionadas con deformaciones de carrocería, patrones de aplastamiento, regiones de impacto y otros indicadores visuales asociados con la severidad de la colisión.

Con el propósito de adaptar dichas representaciones al problema específico de estimación de velocidad vehicular, se implementó una etapa de *Fine-Tuning* controlado sobre las capas más profundas de ResNet50. Esta estrategia permitió especializar las características visuales previamente aprendidas para capturar patrones particulares presentes en vehículos siniestrados, conservando simultáneamente la capacidad general de extracción de características adquirida durante el entrenamiento original sobre ImageNet.

Posteriormente, las características visuales generadas por ResNet50 son procesadas mediante un bloque de generación de embeddings encargado de proyectar las representaciones originales de alta dimensionalidad hacia un espacio latente compacto de 512 dimensiones. Este espacio latente fue diseñado con el objetivo de concentrar la información visual más relevante para la tarea de regresión, reduciendo redundancias y favoreciendo la construcción de representaciones semánticamente organizadas del daño vehicular.

Finalmente, los embeddings generados son utilizados

como entrada de una red neuronal completamente conectada (*Fully Connected Regressor*), responsable de realizar la estimación final de velocidad mediante una única neurona de salida con activación lineal. La Figura 6 muestra la arquitectura general implementada para el modelo ImageVelocityEstimator.




Figura 6: Arquitectura de ImageVelocityEstimator

2. Proceso de Entrenamiento

Con el objetivo de identificar la configuración de mayor desempeño, se llevaron a cabo múltiples iteraciones experimentales evaluando distintas variantes arquitectónicas y estrategias de optimización.

Las configuraciones exploradas incluyeron diferentes esquemas de ajuste fino de ResNet50, funciones de optimización, tasas de aprendizaje, estrategias de regularización, técnicas de aumento de datos (*Data Augmentation*), estructuras alternativas para el espacio latente y diversas configuraciones para la red de regresión final.

Las técnicas de aumento de datos fueron incorporadas con el propósito de incrementar la variabilidad visual observada durante el entrenamiento y mejorar la capacidad de generalización del modelo frente a cambios en iluminación, orientación, encuadre y condiciones de captura de las imágenes. Paralelamente, se evaluaron diferentes mecanismos de regularización para reducir el riesgo de sobreajuste derivado del tamaño limitado del conjunto de datos disponible.

La selección de la configuración final se realizó mediante evaluación sistemática sobre los conjuntos de entrenamiento y validación, considerando principalmente métricas de error absoluto medio (MAE) y la estabilidad observada durante el proceso de convergencia.

3. Configuración Experimental Seleccionada

Como resultado del proceso iterativo de experimentación descrito anteriormente, se identificó una configuración que obtuvo el mejor desempeño global entre las distintas variantes evaluadas para ImageVelocityEstimator. Esta configuración fue posteriormente adoptada como la versión definitiva del modelo visual y utilizada como encoder dentro de la arquitectura multimodal HybridVelocityEstimator.

El experimento seleccionado se construyó sobre una arquitectura ResNet50 preentrenada sobre ImageNet utilizando una estrategia de *Transfer Learning* con ajuste fino parcial (*Fine-Tuning*) de las capas más profundas del backbone. Específicamente, se habilitó el entrenamiento de los bloques correspondientes a `resnet.layer4`, permitiendo especializar las representaciones visuales de alto nivel para la identificación de patrones asociados con daños vehiculares y severidad de impacto, mientras que las capas anteriores conservaron los pesos adquiridos durante el

preentrenamiento.

Con el propósito de incrementar la capacidad de representación de la arquitectura, se incorporó un bloque personalizado de generación de embeddings compuesto por una capa completamente conectada que proyecta las características extraídas por ResNet50 desde 2048 dimensiones hacia un espacio latente compacto de 512 dimensiones. Este bloque incluye Batch Normalization, función de activación GELU y una capa Dropout con probabilidad de 0.3, favoreciendo la estabilidad del entrenamiento y reduciendo el riesgo de sobreajuste.

La etapa final de regresión fue implementada mediante una arquitectura *Fully Connected* compuesta por una capa oculta de 128 neuronas seguida de Batch Normalization, activación GELU y Dropout con probabilidad de 0.2. Finalmente, una neurona lineal de salida genera la estimación continua de velocidad precolisión. Esta configuración fue seleccionada tras evaluar distintas alternativas para la dimensionalidad de los embeddings y la complejidad del regresor, observándose un equilibrio favorable entre capacidad de representación y generalización.

Durante el entrenamiento se utilizó un conjunto de datos aumentado compuesto por 15,513 imágenes, generado mediante técnicas de *Data Augmentation* orientadas a incrementar la variabilidad visual observada por la red neuronal. Todas las imágenes fueron normalizadas utilizando estadísticas calculadas sobre el conjunto de entrenamiento y posteriormente redimensionadas a una resolución de 224×224 píxeles, compatible con la arquitectura ResNet50.

La optimización se realizó durante un máximo de 60 épocas utilizando un tamaño de lote de 128 muestras y una tasa de aprendizaje inicial de 1×10^{-4} . Adicionalmente, se incorporó un mecanismo de *Early Stopping* con una paciencia de 20 épocas para prevenir sobreajuste y detener automáticamente el entrenamiento cuando no se observaran mejoras significativas en el desempeño de validación. El entrenamiento fue ejecutado sobre una GPU (NVIDIA GeForce RTX 4060 8Gb vRAM) utilizando precisión mixta (*bf16-mixed*) con el objetivo de reducir el consumo de memoria y acelerar el proceso de optimización.

Una de las modificaciones más relevantes respecto a experimentos anteriores consistió en sustituir la función de pérdida *Smooth L1 Loss* por *L1 Loss* (Error Absoluto Medio). Esta decisión permitió alinear directamente el proceso de optimización con la métrica principal utilizada durante la evaluación del modelo, favoreciendo una reducción más consistente del error absoluto medio observado sobre los conjuntos de validación y prueba.

La Tabla 1 resume los principales hiperparámetros y características de la configuración seleccionada.

TABLA 1: CONFIGURACIÓN EXPERIMENTAL SELECCIONADA PARA IMAGEVELOCITYESTIMATOR

Parámetro	Valor
Backbone	ResNet50 preentrenada en ImageNet
Fine-Tuning	Descongelamiento de <code>layer4</code>
Resolución de entrada	224×224 píxeles
Dataset de entrenamiento	15 513 imágenes aumentadas mediante Data Augmentation
Embedding visual	512 dimensiones
Función de activación	GELU
Dropout (Embedding Layer)	0.3
Dropout (Regressor)	0.2
Batch Size	128
Learning Rate	1×10^{-4}
Épocas máximas	60
Early Stopping	Paciencia de 20 épocas
Función de pérdida	L1 Loss (MAE)
Optimizador	AdamW
Precisión de entrenamiento	bf16-mixed
Semilla aleatoria	42

4. Análisis del Espacio Latente

Además de la evaluación tradicional basada en métricas de regresión, se realizó un análisis exploratorio orientado a comprender la calidad de las representaciones internas aprendidas por la red neuronal.

Para ello se extrajeron los embeddings visuales de 512 dimensiones generados inmediatamente antes de la etapa de regresión. Desde una perspectiva conceptual, estos embeddings constituyen la representación interna que el modelo construye sobre cada vehículo colisionado, codificando en forma matemática las características visuales que considera relevantes para inferir la velocidad del impacto.

Con el objetivo de analizar la organización de este espacio latente, se aplicaron múltiples técnicas de reducción de dimensionalidad que permitieron proyectar los embeddings hacia espacios bidimensionales para su posterior visualización. Este procedimiento tuvo como finalidad determinar si las representaciones aprendidas por la red exhibían patrones de agrupamiento asociados a diferentes niveles de velocidad.

d. Modelo Basado en Variables Tabulares

Con el objetivo de evaluar la capacidad predictiva de la información estructurada disponible en procesos de reconstrucción de accidentes de tránsito, se formuló la hipótesis de que la velocidad vehicular precolisión puede estimarse a partir de variables tabulares derivadas exclusivamente de investigaciones forenses, prescindiendo del análisis de imágenes postcolisión. Para validar esta hipótesis se diseñaron tres estrategias de preprocesamiento y se evaluaron distintos modelos supervisados de regresión.

1. Pipelines de Preprocesamiento

Pipeline de Preprocesamiento 1 - La primera estrategia de preprocesamiento tuvo como objetivo conservar la totalidad de la información disponible mediante un conjunto de transformaciones estándar de preparación de datos, implementadas mediante un flujo estructurado basado en *scikit-learn* que aplicó transformaciones diferenciadas a

cada tipo de atributo a través de un `ColumnTransformer`. Como paso inicial, se eliminaron todos aquellos registros que no contenían una medición válida de velocidad asociada al impacto, dado que la ausencia de la variable objetivo imposibilita el entrenamiento supervisado, y se excluyeron adicionalmente aquellas columnas consideradas no informativas para el modelado. Tras este filtrado, el conjunto de datos quedó compuesto por 240 registros únicos y 23 características predictoras.

Las variables numéricas continuas incluidas en este pipeline fueron el peso base del vehículo en vacío (`curbWeightKg`), expresado en kilogramos, y el peso adicional transportado por el vehículo (`cargoWeightKg`), también en kilogramos. Estas variables se imputaron mediante la mediana de cada atributo, estrategia robusta ante la presencia de valores atípicos, y posteriormente fueron normalizadas aplicando estandarización Z-score, de modo que cada variable resultante presentara media cero y desviación estándar unitaria, condición requerida para garantizar la estabilidad numérica del proceso de optimización en modelos basados en gradiente.

Las variables categóricas nominales fueron imputadas en primera instancia mediante una categoría genérica para gestionar la presencia de valores faltantes, y posteriormente codificadas mediante *One-Hot Encoding*, técnica que genera una representación binaria independiente para cada categoría y evita la introducción artificiosa de relaciones de orden entre clases. Las dos variables nominales consideradas fueron la clase vehicular (`vehicleClass`) y el plano principal de daño (`damagePlaneDescription`). La clase vehicular se definió en función de la distancia entre ejes (`wheelbase`) del vehículo, diferenciando cinco categorías: *Subcompact/mini* para vehículos con wheelbase inferior a 254 cm, *Compact* para wheelbase entre 254 cm y 265 cm, *Intermediate* para wheelbase entre 265 cm y 278 cm, *Full-size* para wheelbase entre 278 cm y 291 cm, y *Compact Utility Vehicle* como categoría independiente de los segmentos anteriores. El plano principal de daño identificó la región del vehículo con mayor afectación estructural, distinguiendo seis categorías: frontal (*Front*), trasero (*Back*), lateral izquierdo (*Left side*), lateral derecho (*Right side*), techo (*Top*) y parte inferior (*Undercarriage*).

Dado que ciertas variables de naturaleza angular exhiben una propiedad de circularidad que no puede ser preservada mediante codificaciones lineales convencionales, se aplicó una transformación trigonométrica basada en funciones seno y coseno. Bajo este esquema, cada ángulo θ fue descompuesto en un par de componentes ortogonales— $\sin(\theta)$ y $\cos(\theta)$ —que capturan la continuidad del espacio angular y evitan la discontinuidad artificial que introduciría una representación escalar en los extremos del intervalo. Las variables resultantes de esta codificación fueron `forceDirection_sin`, `forceDirection_cos`, `clockDirection_sin` y `clockDirection_cos`, representando respectivamente la dirección de la fuerza de impacto y la dirección horaria asociada al vector de colisión.

Las variables con orden inherente fueron codificadas preservando explícitamente su jerarquía mediante asignación ordinal. La descripción de severidad del accidente (`severityDescription`) fue tratada como variable ordinal

respetando un orden de gravedad predefinido, lo que permite al modelo reconocer y explotar la relación de orden entre niveles. El índice máximo de escala abreviada de lesiones (*mais*, *Maximum Abbreviated Injury Scale*) requirió un tratamiento previo adicional consistente en la extracción de su componente numérico antes de proceder a la imputación y escalado, dado que su representación original en el conjunto de datos incorporaba información de formato no estrictamente numérico; una vez extraído dicho componente, la variable fue procesada de manera análoga a *severityDescription*. La variable binaria *rolloverStatus*, indicadora de si el vehículo experimentó un vuelco durante el accidente, fue originalmente registrada como una variable categórica nominal con dos posibles valores: *No rollover*, denotando la ausencia de volcadura, y *Rollover — Longitudinal axis*, denotando la ocurrencia de volcadura sobre el eje longitudinal del vehículo. Esta variable fue transformada mediante binarización, asignando el valor 0 a la categoría de ausencia de volcadura y el valor 1 a la presencia de la misma, obteniendo así una variable indicadora de naturaleza discreta apta para su incorporación directa al proceso de entrenamiento.

La variable objetivo utilizada en todos los experimentos correspondió a la velocidad de cambio total (*total delta-V*), representada en kilómetros por hora mediante la variable *totalDeltaVKph*. El *delta-V* es la magnitud cinemática de referencia en reconstrucción de accidentes y cuantifica el cambio en el vector velocidad del vehículo como consecuencia directa del impacto, constituyendo el indicador más empleado para caracterizar la severidad biomecánica del evento.

TABLA 2: VARIABLES DEL PIPELINE DE PREPROCESAMIENTO 1 (240 REGISTROS, 23 CARACTERÍSTICAS)

Variable	Tipo / Original	Transformación
<i>curbWeightKg</i>	Numérica continua	Imputación mediana + Z-score
<i>cargoWeightKg</i>	Numérica continua	Imputación mediana + Z-score
<i>vehicleClass</i>	Categórica nominal	Imputación categórica + One-Hot
<i>damagePlaneDes</i>	Categórica nominal	Imputación categórica + One-Hot
<i>forceDirection_sin</i>	Cíclica	$\sin(\theta)$
<i>forceDirection_cos</i>	Cíclica	$\cos(\theta)$
<i>clockDirection_sin</i>	Cíclica	$\sin(\theta)$
<i>clockDirection_cos</i>	Cíclica	$\cos(\theta)$
<i>severityDescription</i>	Ordinal	Codificación ordinal
<i>mais</i>	Ordinal	Extracción numérica + codificación ordinal
<i>rolloverStatus</i>	Categórica nominal	Binarización (0 = no volcadura, 1 = volcadura)

Pipeline de Preprocesamiento 2 - El segundo pipeline conservó íntegramente las transformaciones aplicadas en el pipeline anterior a las variables numéricas continuas, ordinales, binarias y cíclicas, pero sustituyó la codificación One-Hot por una estrategia de *Target Encoding* para las variables categóricas nominales. Bajo este esquema, cada categoría fue reemplazada por un valor numérico derivado de la media condicional de la variable objetivo correspondiente a dicha categoría, calculada exclusivamente sobre el conjunto de entrenamiento para evitar fuga de información hacia los conjuntos de validación y prueba. Esta sustitución redujo

significativamente la dimensionalidad del espacio de entrada al eliminar la expansión binaria característica del *One-Hot Encoding*, lo que resulta particularmente relevante en conjuntos de datos de tamaño moderado donde el incremento de dimensiones puede derivar en problemas de sobreajuste.

Como resultado de estas transformaciones, el conjunto final quedó compuesto por 288 registros únicos y 11 características predictoras. El incremento en el número de registros respecto al pipeline anterior se explica por la estrategia de enriquecimiento de la variable objetivo descrita a continuación.

Con el propósito de incrementar el número de observaciones disponibles para entrenamiento sin alterar la naturaleza física de la variable objetivo, se integraron dos fuentes de información cinemática presentes en la base de datos CIREN: la medición reconstruida del *delta-V* total (*totalDeltaV*) y la estimación de velocidad equivalente a barrera obtenida mediante simulación computacional (*dvBarrierEquivalentSpeedDescription*). Cuando ambas mediciones estaban disponibles para un mismo registro, se priorizó el valor reconstruido por su mayor fidelidad a las condiciones reales del accidente. En ausencia de esta medición, se utilizó la estimación derivada de simulación como aproximación cinemática. Esta estrategia de fusión permitió ampliar la cobertura del conjunto de datos, incorporando registros que de otro modo habrían sido descartados por carecer de la medición primaria.

TABLA 3: VARIABLES DEL PIPELINE DE PREPROCESAMIENTO 2 (288 REGISTROS, 11 CARACTERÍSTICAS)

Variable	Tipo / Original	Transformación
<i>curbWeightKg</i>	Numérica continua	Imputación mediana + Z-score
<i>cargoWeightKg</i>	Numérica continua	Imputación mediana + Z-score
<i>vehicleClass</i>	Categórica nominal	Imputación categórica + Target Encoding
<i>damagePlaneDes</i>	Categórica nominal	Imputación categórica + Target Encoding
<i>forceDirection_sin</i>	Cíclica	$\sin(\theta)$
<i>forceDirection_cos</i>	Cíclica	$\cos(\theta)$
<i>clockDirection_sin</i>	Cíclica	$\sin(\theta)$
<i>clockDirection_cos</i>	Cíclica	$\cos(\theta)$
<i>severityDescription</i>	Ordinal	Codificación ordinal
<i>mais</i>	Ordinal	Extracción numérica + codificación ordinal
<i>rolloverStatus</i>	Categórica nominal	Binarización (0 = no volcadura, 1 = volcadura)

Pipeline de Preprocesamiento 3 - La tercera estrategia de preprocesamiento se construyó sobre las transformaciones del Pipeline 2 e incorporó una etapa adicional de selección de características orientada a eliminar predictores redundantes o irrelevantes, con el fin de reducir el ruido en el espacio de entrada y mejorar la capacidad de generalización de los modelos.

El proceso de selección se desarrolló en tres fases sucesivas. En primer lugar, se identificaron y eliminaron variables constantes o cuasi-constantes, es decir, aquellas cuya varianza era inferior a un umbral mínimo, dado que carecen de capacidad discriminatoria respecto a la variable objetivo.

En segundo lugar, se calculó la *Información Mutua* (*Mutual Information*, MI) entre cada predictor y la velocidad

objetivo. Esta métrica no paramétrica cuantifica la dependencia estadística entre dos variables, independientemente de la forma funcional de dicha relación. Las variables cuyo valor de MI fue inferior a 0.001 fueron descartadas por no aportar información relevante sobre la variabilidad de la velocidad de impacto.

En tercer lugar, se realizó un análisis de correlación de Pearson entre los predictores restantes. Cuando dos variables presentaban una correlación superior a 0.90, indicativa de multicolinealidad severa, se conservó únicamente aquella con mayor valor de Información Mutua, eliminando la variable redundante.

Como resultado de este proceso de selección, el conjunto final quedó compuesto por 288 registros y 7 características predictoras. Las variables seleccionadas fueron: el peso en vacío del vehículo (*curbWeightKg*), la clase vehicular (*vehicleClass*), el plano principal de daño (*damagePlaneDescription*), las componentes seno y coseno de la dirección de la fuerza de impacto (*forceDirection_sin* y *forceDirection_cos*), la descripción de severidad del accidente (*severityDescription*) y el índice máximo de lesión abreviada (*mais*).

Este subconjunto representa las variables con mayor capacidad predictiva individual y menor redundancia mutua respecto a la velocidad vehicular precolisión dentro del conjunto de datos analizado.

TABLA 4: VARIABLES SELECCIONADAS POR EL PIPELINE DE PREPROCESAMIENTO 3 (288 REGISTROS, 7 CARACTERÍSTICAS)

Variable	Tipo Original	Transformación
curbWeightKg	Númerica continua	Imputación mediana + Z-score
vehicleClass	Categorica nominal	Imputación categórica + Target Encoding
damagePlaneDes	Categorica nominal	Imputación categórica + Target Encoding
forceDirection_sin	Cíclica	$\sin(\theta)$
forceDirection_cos	Cíclica	$\cos(\theta)$
severityDescription	Ordinal	Codificación ordinal
mais	Ordinal	Extracción numérica + codificación ordinal

2. Modelos Evaluados

Con el propósito de analizar de manera sistemática la influencia del preprocesamiento sobre el desempeño predictivo, se evaluaron cuatro configuraciones experimentales que combinan distintas estrategias de transformación de datos con dos familias de modelos de regresión supervisada. Los tres primeros experimentos emplearon una Red Neuronal Multicapa (Multilayer Perceptron, MLP), mientras que el cuarto utilizó un modelo de potenciación de gradiente basado en árboles de decisión (XGBoost). La partición de datos fue idéntica en todos los casos, asignando el 64% de los registros al conjunto de entrenamiento, el 16% al conjunto de validación y el 20% restante al conjunto de prueba, garantizando así la comparabilidad de los resultados entre configuraciones.

Los experimentos fueron ejecutados en una estación de trabajo equipada con un procesador Intel® Core™ i9-14900HX (2.20 GHz), 32 GB de memoria RAM y una unidad de procesamiento gráfico NVIDIA GeForce RTX

4070 con 8 GB de memoria VRAM. El sistema operativo utilizado fue de 64 bits con arquitectura x64.

Red Neuronal Multicapa (MLP) - Se implementó una arquitectura completamente conectada (fully connected) compuesta por tres capas ocultas con 64, 32 y 16 neuronas respectivamente, siguiendo una estructura de tipo embudo que condensa progresivamente la representación aprendida a lo largo de las capas. Todas las unidades ocultas emplearon la función de activación ReLU (Rectified Linear Unit), y la capa de salida consistió en una única neurona lineal acorde con la naturaleza continua de la variable objetivo.

Para mitigar el sobreajuste se incorporó regularización mediante Dropout con una tasa del 5%, aplicada tras cada capa oculta, técnica que durante el entrenamiento desactiva aleatoriamente una fracción de las neuronas, forzando al modelo a aprender representaciones más robustas y distribuidas. El entrenamiento se realizó con un tamaño de batch de 16 muestras y una tasa de aprendizaje de 0.0003, utilizando el Error Cuadrático Medio (MSE) como función de pérdida. Se estableció un máximo de 100 épocas de entrenamiento con un criterio de parada anticipada (Early Stopping) de 10 épocas consecutivas sin mejora en la pérdida de validación, con el fin de evitar el sobreajuste y reducir el tiempo de cómputo. Los tres experimentos realizados con esta arquitectura se denominaron MLP-P1, MLP-P2 y MLP-P3, correspondiendo cada uno al pipeline de preprocesamiento homónimo.

TABLA 5: ARQUITECTURA E HIPERPARÁMETROS DE LA RED NEURONAL MULTICAPA (MLP)

Parámetro	Valor	Descripción
Tipo de arquitectura	Fully connected (MLP)	Red neuronal completamente conectada
Número de capas ocultas	3	Estructura tipo embudo
Neuronas — Capa 1	64	Primera capa oculta
Neuronas — Capa 2	32	Segunda capa oculta
Neuronas — Capa 3	16	Tercera capa oculta
Función de activación	ReLU	Rectified Linear Unit en capas ocultas
Capa de salida	1 neurona lineal	Regresión de variable continua
Regularización	Dropout 5%	Aplicado tras cada capa oculta
Tamaño de batch	16	Muestras por iteración de gradiente
Tasa de aprendizaje	0.0003	Learning rate del optimizador
Épocas máximas	100	Límite superior de iteraciones de entrenamiento
Early Stopping	10 épocas	Paciencia sin mejora en pérdida de validación
Función de pérdida	MSE	Error Cuadrático Medio
Métrica de evaluación	MAE	Error Absoluto Medio (km/h)

XGBoost para Regresión - Como alternativa al paradigma neuronal, se implementó un modelo XGBoost (eXtreme Gradient Boosting) para regresión, familia de métodos que construye un ensamble de árboles de decisión de manera secuencial, donde cada árbol sucesivo corrige los errores residuales del conjunto previamente entrenado

mediante descenso de gradiente sobre una función de pérdida diferenciable. Este modelo fue entrenado utilizando el conjunto de características seleccionadas por el Pipeline 3.

Los hiperparámetros del modelo fueron configurados de la siguiente manera: el número máximo de estimadores (árboles) se fijó en 1000, la profundidad máxima de cada árbol en 5 niveles, la tasa de aprendizaje (shrinkage) en 0.05 para controlar la contribución de cada árbol individual al ensamble, y las tasas de submuestreo de instancias y características en 0.80 para ambos casos, lo que introduce variabilidad estocástica en cada iteración y reduce la correlación entre árboles. Se aplicó un criterio de parada anticipada de 50 rondas consecutivas sin mejora en la pérdida de validación. La función objetivo minimizada durante el entrenamiento fue el Error Cuadrático Medio, mientras que la métrica empleada para la evaluación comparativa entre modelos fue el Error Absoluto Medio (MAE), dada su interpretabilidad directa en unidades físicas de velocidad (km/h) y su menor sensibilidad a valores atípicos respecto al RMSE.

TABLA 6: HIPERPARÁMETROS DEL MODELO XGBOOST PARA REGRESIÓN

Hiperparámetro	Valor	Descripción
n_estimators	1000	Número máximo de árboles en el ensamble
max_depth	5	Profundidad máxima de cada árbol individual
learning_rate	0.05	Tasa de contracción (shrinkage) por árbol
subsample	0.80	Fracción de instancias muestreadas por árbol
colsample_bytree	0.80	Fracción de características muestreadas por árbol
early_stopping_rounds	50	Rondas consecutivas sin mejora para detención anticipada
Función objetivo	MSE	Error Cuadrático Medio (entrenamiento)
Métrica de evaluación	MAE	Error Absoluto Medio (km/h)

e. Modelo Híbrido

Los resultados obtenidos durante el desarrollo de los enfoques unimodales permitieron identificar fortalezas y limitaciones complementarias en cada modalidad de información. Por una parte, el modelo basado en imágenes demostró la capacidad de aprender representaciones visuales asociadas con la severidad de los daños estructurales y con la velocidad precolisión, aunque su desempeño se encontraba limitado por la ausencia de información contextual y técnica del accidente. Por otra parte, el modelo basado en variables tabulares logró capturar relaciones estadísticas relevantes entre atributos derivados de procesos de reconstrucción forense y la velocidad de impacto, pero carecía de acceso a la información visual contenida en las deformaciones observables de los vehículos involucrados.

A partir de estas observaciones se formuló una nueva hipótesis de investigación: si ambas modalidades describen aspectos complementarios del mismo fenómeno físico, entonces la integración conjunta de información visual e

información estructurada podría permitir la construcción de representaciones más completas del siniestro y, en consecuencia, mejorar la precisión de las estimaciones de velocidad precolisión.

Con el propósito de validar esta hipótesis se desarrolló una arquitectura multimodal denominada *HybridVelocityEstimator*, diseñada para combinar simultáneamente evidencia visual proveniente de imágenes postcolisión y variables tabulares derivadas de procesos de reconstrucción de accidentes. El objetivo principal de esta arquitectura consiste en aprovechar las fortalezas de cada modalidad dentro de un único proceso de inferencia, permitiendo que el modelo disponga de una descripción más rica y completa de cada evento.

Desde una perspectiva conceptual, el modelo busca aproximar una función donde la velocidad precolisión depende tanto de las características visuales observables en el vehículo siniestrado como de los atributos técnicos asociados al caso. En lugar de obligar a una única fuente de información a explicar completamente el fenómeno, la arquitectura distribuye el aprendizaje entre dos ramas especializadas que posteriormente son fusionadas dentro de una representación conjunta.

1. Arquitectura Propuesta

La arquitectura recibe dos entradas para cada muestra del conjunto de datos:

- Una imagen correspondiente al vehículo colisionado.
- Un vector de variables tabulares asociado al mismo caso.

La rama visual reutiliza el modelo *ImageVelocityEstimator* previamente desarrollado, empleándolo como un encoder especializado de características visuales. Bajo esta configuración, la imagen es procesada por el backbone ResNet50 y por el bloque de generación de embeddings hasta producir una representación latente de 512 dimensiones.

Este embedding constituye la representación interna que el modelo construye sobre la evidencia visual disponible y concentra información relacionada con la severidad del daño estructural, los patrones de deformación observados en la carrocería, la distribución espacial de los impactos y otras características visuales relevantes para la estimación de velocidad.

De manera paralela, las variables tabulares correspondientes al mismo caso son procesadas mediante los pipelines de preprocesamiento descritos en la sección anterior, obteniendo una representación estructurada de las características técnicas del accidente.

Una vez obtenidas ambas representaciones, se aplica una operación de concatenación que constituye el mecanismo de fusión multimodal empleado por la arquitectura. Esta estrategia permite preservar íntegramente la información aportada por cada modalidad antes de iniciar el proceso de aprendizaje conjunto.

Como resultado de esta etapa se genera un vector multimodal compuesto por:

Embedding Visual (512 dimensiones) + Variables Tabulares

La Figura 7 muestra la arquitectura general implementada para el modelo HybridVelocityEstimator.




Figura 7: Arquitectura propuesta para HybridVelocityEstimator

2. Regresor Multimodal

La representación fusionada es procesada mediante una red neuronal completamente conectada diseñada específicamente para aprender relaciones cruzadas entre ambas modalidades.

La arquitectura implementada utiliza una estructura de reducción progresiva de dimensionalidad compuesta por capas ocultas de 512, 256, 128 y 64 neuronas respectivamente. Cada bloque incorpora Batch Normalization, función de activación GELU y mecanismos de regularización mediante Dropout.

La utilización de Batch Normalization contribuye a estabilizar la distribución interna de activaciones durante el entrenamiento, facilitando la convergencia del modelo y reduciendo la sensibilidad a la inicialización de parámetros. Por su parte, la activación GELU introduce una transformación no lineal suave que ha demostrado un desempeño superior al de funciones clásicas como ReLU en diversas arquitecturas profundas. Finalmente, la incorporación de Dropout permite reducir el riesgo de sobreajuste mediante la desactivación aleatoria de neuronas durante el entrenamiento.

La estructura de reducción progresiva fue diseñada con el objetivo de permitir que el modelo aprenda representaciones cada vez más abstractas a medida que la información avanza a través de la red. Este proceso favorece la construcción de relaciones complejas entre características visuales y variables tabulares, capturando interacciones que difícilmente podrían ser modeladas por cualquiera de las modalidades de forma independiente.

La arquitectura concluye con una única neurona lineal de salida encargada de generar la estimación continua de velocidad precolisión.

3. Proceso de Entrenamiento

Una vez definida la arquitectura, se llevó a cabo una etapa extensa de experimentación orientada a optimizar el desempeño del modelo. Al igual que en los enfoques anteriores, se evaluaron múltiples configuraciones relacionadas con hiperparámetros, tasas de aprendizaje, mecanismos de regularización y configuraciones internas de la red de regresión.

La evaluación sistemática de estas configuraciones permitió identificar la combinación de parámetros con mejor desempeño sobre los conjuntos de validación y

prueba. Durante esta etapa se observó un comportamiento particularmente estable de las curvas de entrenamiento, caracterizado por una convergencia consistente y por la ausencia de divergencias significativas entre las métricas de entrenamiento y validación.

Este comportamiento constituye un indicio de que la arquitectura fue capaz de aprovechar la información adicional proporcionada por ambas modalidades para construir representaciones más robustas y generalizables que las obtenidas por los enfoques unimodales.

4. Diseño Modular y Reutilización del Encoder Visual

Una de las decisiones arquitectónicas más relevantes implementadas en HybridVelocityEstimator consiste en reutilizar el modelo ImageVelocityEstimator como un encoder visual independiente encargado de generar las representaciones latentes utilizadas durante el proceso de fusión multimodal.

A diferencia de arquitecturas multimodales monolíticas entrenadas completamente de extremo a extremo, el enfoque propuesto desacopla la generación de características visuales del proceso de aprendizaje multimodal. Bajo esta estrategia, ImageVelocityEstimator es entrenado previamente hasta aprender un espacio latente especializado en la representación de daños vehiculares y posteriormente es reutilizado únicamente como extractor de características dentro de la arquitectura híbrida.

Esta decisión aporta múltiples ventajas desde la perspectiva computacional y de ingeniería de software. En primer lugar, permite reducir significativamente la cantidad de parámetros entrenables durante la etapa multimodal. Dado que ResNet50 contiene aproximadamente 25 millones de parámetros, congelar el encoder visual evita la necesidad de propagar gradientes a través de toda la red convolucional durante cada iteración de entrenamiento.

Como consecuencia, se reduce el consumo de memoria GPU, disminuyen los tiempos de entrenamiento y se facilita la experimentación con distintas configuraciones del bloque multimodal.

Adicionalmente, esta estrategia introduce una separación clara de responsabilidades entre componentes. Mientras ImageVelocityEstimator se especializa en aprender representaciones visuales del daño vehicular, HybridVelocityEstimator se enfoca exclusivamente en aprender la relación existente entre dichas representaciones, las variables tabulares y la velocidad objetivo.

Esta modularidad facilita significativamente la mantenibilidad y evolución futura del sistema.

5. Escalabilidad y Evolución del Sistema

El desacoplamiento arquitectónico implementado permite además aprovechar conjuntos de datos heterogéneos de manera independiente.

En escenarios reales, los conjuntos de datos multimodales completos, que contienen simultáneamente imágenes, variables tabulares y velocidades reconstruidas, suelen ser considerablemente más escasos que aquellos compuestos únicamente por imágenes etiquetadas. Gracias a la modularidad del diseño, ImageVelocityEstimator puede continuar entrenándose y mejorándose utilizando grandes

volúmenes de datos visuales sin requerir la disponibilidad simultánea de variables tabulares asociadas.

Como consecuencia, cualquier mejora obtenida en la calidad de las representaciones visuales generadas por el encoder puede transferirse directamente al sistema multimodal sin necesidad de rediseñar la arquitectura híbrida. Embeddings más discriminativos permiten proporcionar información visual más rica al bloque de fusión, incrementando potencialmente la capacidad predictiva del modelo final.

Desde esta perspectiva, HybridVelocityEstimator constituye una arquitectura modular, escalable y sostenible, diseñada no sólo para maximizar el desempeño sobre el conjunto de datos disponible, sino también para facilitar futuras iteraciones de investigación y aprovechar nuevas fuentes de información conforme estas se encuentren disponibles.

IV. RESULTADOS

a. Resultados del Modelo Basado en Imágenes

Esta sección presenta los resultados obtenidos por el modelo ImageVelocityEstimator, desarrollado para estimar la velocidad precolisión utilizando exclusivamente evidencia visual proveniente de imágenes de vehículos siniestrados. El desempeño del modelo se evaluó mediante el Error Absoluto Medio (MAE) sobre los conjuntos de validación y prueba, complementando el análisis cuantitativo con curvas de aprendizaje, diagramas de dispersión entre velocidades reales y estimadas, así como visualizaciones del espacio latente aprendido por la red neuronal. Estas representaciones permiten analizar tanto la capacidad predictiva del modelo como la calidad de las características visuales extraídas durante el proceso de entrenamiento.

El modelo alcanzó un MAE de validación de 11.504 km/h y un MAE de prueba de 12.534 km/h. Los resultados obtenidos demuestran que la información contenida en las deformaciones estructurales visibles después de una colisión resulta suficientemente informativa para que una red neuronal profunda aprenda relaciones significativas con la velocidad precolisión.

Las curvas de aprendizaje muestran un proceso de convergencia estable tanto para los conjuntos de entrenamiento como de validación, sin evidencias significativas de sobreajuste durante las etapas finales del entrenamiento. La evolución consistente del Error Absoluto Medio a lo largo de las épocas sugiere que la arquitectura logró extraer características visuales relevantes y generalizables a partir de las imágenes disponibles. Las curvas de aprendizaje correspondientes se presentan en la Figura 8.




Figura 8: Curvas de aprendizaje del Error Absoluto Medio (MAE) para el modelo ImageVelocityEstimator

El análisis del diagrama de dispersión entre velocidades predichas y velocidades reales permite caracterizar con mayor detalle el comportamiento del modelo a lo largo del rango dinámico de velocidades presente en el conjunto de datos. Para velocidades bajas y medias, las predicciones presentan una dispersión relativamente acotada alrededor de la línea de identidad, indicando que el modelo es capaz de capturar patrones visuales consistentes asociados con niveles moderados de daño estructural. Sin embargo, conforme la velocidad real aumenta, se observa una degradación progresiva en la precisión de las estimaciones.

Particularmente, a partir de aproximadamente 60 km/h comienza a manifestarse una tendencia sistemática de subestimación, donde eventos de alta severidad son proyectados hacia rangos de velocidad considerablemente inferiores. Este comportamiento resulta consistente con la distribución del conjunto de datos utilizado para entrenamiento, caracterizado por una representación significativamente menor de accidentes de alta energía en comparación con colisiones de baja y media severidad. Como consecuencia, el modelo dispone de una cantidad limitada de ejemplos para aprender adecuadamente las características visuales distintivas de impactos a velocidades elevadas. El diagrama de dispersión correspondiente se presenta en la Figura 9.




Figura 9: Diagrama de dispersión entre velocidades predichas y velocidades reales para el modelo ImageVelocityEstimator

Con el propósito de analizar la calidad de las representaciones internas aprendidas por la red neuronal, se realizó un estudio adicional sobre los embeddings visuales de 512 dimensiones generados por la arquitectura antes de la etapa final de regresión. Dichos embeddings constituyen la

representación latente que el modelo construye sobre cada vehículo colisionado y permiten examinar si la red está organizando las muestras de acuerdo con patrones visuales relacionados con la variable objetivo.

Para facilitar su interpretación, los embeddings fueron proyectados a espacios bidimensionales mediante distintas técnicas de reducción de dimensionalidad. Los resultados obtenidos evidencian la aparición de agrupamientos y gradientes coherentes con la distribución de velocidades observadas en los datos. Las muestras correspondientes a velocidades similares tienden a concentrarse en regiones próximas del espacio latente, mientras que los accidentes asociados a mayores niveles de severidad se desplazan progresivamente hacia zonas diferenciadas de la representación aprendida.

Este comportamiento constituye evidencia directa de que la red neuronal logró capturar características visuales semánticamente significativas relacionadas con la magnitud del daño estructural y con la velocidad precolisión asociada a cada evento. Las visualizaciones del espacio latente se presentan en la Figura 10.




Figura 10: Visualización bidimensional de los embeddings generados por el modelo ImageVelocityEstimator

b. Resultados del Modelo Basado en Variables Tabulares

Esta sección presenta los resultados obtenidos por cada una de las cuatro configuraciones experimentales evaluadas. El desempeño de los modelos se reporta en términos del Error Absoluto Medio (MAE) calculado sobre los conjuntos de validación y prueba, métrica seleccionada por su interpretabilidad directa en unidades físicas de velocidad (km/h) y su robustez ante valores atípicos. Los resultados se complementan con las curvas de aprendizaje del MAE a lo largo del entrenamiento y con diagramas de dispersión entre velocidades predichas y velocidades reales, que permiten evaluar cualitativamente el comportamiento del modelo a lo largo del rango dinámico de la variable objetivo.

1. MLP con Pipeline de Preprocesamiento 1 (MLP-P1)

El primer experimento evaluó el desempeño de la red neuronal multicapa entrenada sobre el conjunto de 240 registros y 23 características resultantes del Pipeline 1. La representación de variables categóricas mediante One-Hot Encoding preservó la totalidad de las categorías nominales en forma binaria, lo que derivó en un espacio de entrada de dimensionalidad relativamente elevada en relación con el

volumen de datos disponible.

El modelo alcanzó un MAE de validación de 7.1 km/h y un MAE de prueba de 8.4 km/h. La divergencia de 1.3 km/h entre ambas métricas es consistente con la variabilidad estadística esperada en particiones de tamaño moderado y no constituye evidencia de sobreajuste severo; no obstante, refleja la sensibilidad del modelo a la distribución específica de las muestras asignadas a cada subconjunto.

El análisis del diagrama de dispersión entre velocidades predichas y velocidades reales revela un comportamiento sistemático del modelo en el rango dinámico superior de la variable objetivo. Para valores de delta-V inferiores a 70 km/h, las predicciones exhiben una dispersión razonablemente acotada alrededor de la línea de identidad. Sin embargo, a partir de los 70 km/h el modelo manifiesta una tendencia de subestimación pronunciada y consistente: velocidades reales comprendidas en el intervalo de 70 a 110 km/h son proyectadas sistemáticamente hacia el rango de 50 a 70 km/h, lo que indica que la arquitectura no logra capturar adecuadamente la dinámica de los eventos de alta severidad. Este comportamiento puede atribuirse a la escasa representación de observaciones en el extremo superior de la distribución de velocidades dentro del conjunto de entrenamiento, lo que limita la capacidad del modelo para generalizar sobre colisiones de alta energía. Las curvas de aprendizaje y el diagrama de dispersión correspondientes se presentan en las Figura 11 y Figura 12 respectivamente.




Figura 11: Curvas de aprendizaje del Error Absoluto Medio (MAE) para el modelo MLP entrenado con el Pipeline de Preprocesamiento 1




Figura 12: Diagrama de dispersión entre velocidades predichas y velocidades reales para el modelo MLP entrenado con el Pipeline de Preprocesamiento 1

2. MLP con Pipeline de Preprocesamiento 2 (MLP-P2)

El segundo experimento empleó la misma arquitectura neuronal entrenada sobre un conjunto ampliado de 288 registros y 11 características, resultado de dos modificaciones sustanciales respecto al pipeline anterior: la sustitución de One-Hot Encoding por Target Encoding para las variables categóricas nominales, y la integración de mediciones reconstruidas con estimaciones de simulación como estrategia de enriquecimiento de la variable objetivo. Ambas modificaciones operaron de manera conjunta, reduciendo la dimensionalidad del espacio de entrada al tiempo que incrementaban el volumen de observaciones disponibles para entrenamiento.

El modelo obtuvo un MAE de validación de 11.6 km/h y un MAE de prueba de 8.5 km/h. La inversión en la relación entre ambas métricas —donde el error sobre el conjunto de prueba resulta inferior al registrado en validación— no indica una mejora artificial del desempeño, sino que refleja la variabilidad estadística inherente a la partición de datos en conjuntos de tamaño moderado, particularmente cuando la distribución de velocidades no es uniforme entre subconjuntos. En términos de error de prueba, MLP-P2 presenta un resultado prácticamente equivalente al de MLP-P1 (8.5 km/h frente a 8.4 km/h), lo que evidencia que la reducción dimensional asociada al Target Encoding no comprometió la capacidad predictiva global del modelo pese a operar con una representación de entrada considerablemente más compacta.

El análisis del diagrama de dispersión permite caracterizar con mayor precisión la distribución de los errores a lo largo del rango de velocidades. Las predicciones de mayor fidelidad se concentran en el segmento de velocidades bajas y medias, donde la densidad de observaciones en el conjunto de entrenamiento es más elevada y la variabilidad de la variable objetivo es más acotada. No obstante, se identifican valores atípicos de relevancia diagnóstica en el extremo inferior del espectro: un subconjunto de eventos con velocidades reales comprendidas entre 30 y 40 km/h fue estimado en el rango de 60 a 70 km/h, lo que sugiere que la representación codificada mediante Target Encoding de ciertas categorías de baja frecuencia puede inducir sesgo de sobreestimación en colisiones de baja energía. En el rango intermedio-alto, comprendido entre 70 y 80 km/h, MLP-P2 exhibe una mejora observable respecto a MLP-P1, lo que indica que el enriquecimiento de la variable objetivo mediante la incorporación de estimaciones de simulación aportó información adicional que benefició la caracterización de eventos en ese intervalo de severidad. Finalmente, para velocidades superiores a 100 km/h, el modelo presenta los errores de mayor magnitud, perpetuando la limitación estructural identificada en el experimento anterior asociada a la escasa representación de colisiones de alta energía en los datos de entrenamiento. Las curvas de aprendizaje y el diagrama de dispersión correspondientes se presentan en las Figuras 13 y 14 respectivamente.




Figura 13: Curvas de aprendizaje del Error Absoluto Medio (MAE) para el modelo MLP entrenado con el Pipeline de Preprocesamiento 2




Figura 14: Diagrama de dispersión entre velocidades predichas y velocidades reales para el modelo MLP entrenado con el Pipeline de Preprocesamiento 2

3. MLP con Pipeline de Preprocesamiento 3 (MLP-P3)

El tercer experimento corresponde a la configuración que incorporó una etapa adicional de selección de características mediante Información Mutua y análisis de correlación, reduciendo el espacio de entrada de 11 a 7 variables de alta relevancia predictiva. Esta reducción implicó descartar aquellos predictores cuya contribución estadística a la estimación del delta-V resultó marginal o redundante respecto a variables de mayor capacidad discriminatoria, permitiendo al modelo concentrar su capacidad representacional en el subconjunto de características más informativo. El modelo fue entrenado sobre los 288 registros disponibles y obtuvo un MAE de validación de 11.9 km/h y un MAE de prueba de 7.3 km/h, constituyendo este último el mejor resultado registrado entre las tres configuraciones de red neuronal evaluadas.

La brecha observada entre el MAE de validación y el MAE de prueba, de 4.6 km/h, es atribuible a la variabilidad estadística de la partición en conjuntos de tamaño moderado y no constituye evidencia concluyente de sobreajuste al conjunto de prueba. Más relevante es el hecho de que la mejora en el error de prueba respecto a MLP-P1 y MLP-P2 —de 8.4 y 8.5 km/h respectivamente a 7.3 km/h— se produce precisamente al reducir la dimensionalidad del espacio de entrada, lo que respalda empíricamente la hipótesis de que la eliminación de variables redundantes y de baja relevancia contribuye positivamente a la capacidad de generalización del modelo sobre datos no observados.

El análisis del diagrama de dispersión revela una mejora cualitativa sustancial respecto a las configuraciones anteriores, particularmente en la franja de velocidades bajas y medias. En el intervalo comprendido entre 15 y 60 km/h, las predicciones exhiben la mayor fidelidad del experimento, con una dispersión acotada alrededor de la línea de identidad y una ausencia notable de los valores atípicos de sobreestimación que afectaron al rango de 30 a 40 km/h en MLP-P2. Esta mejora sugiere que la eliminación de predictores de baja relevancia redujo el ruido en la representación de eventos de baja energía, favoreciendo estimaciones más precisas en dicho segmento. Para velocidades comprendidas entre 60 y 70 km/h, las predicciones presentan una dispersión algo mayor, aunque mantienen una concentración razonable alrededor de la tendencia real, sin evidenciar el colapso predictivo observado en configuraciones anteriores. A partir de los 70 km/h, el modelo manifiesta una tendencia sistemática de subestimación que se intensifica progresivamente con la velocidad: los errores son de magnitud moderada hasta aproximadamente 100 km/h, pero se incrementan de forma marcada para eventos de velocidad superior, donde la escasa densidad de observaciones en el conjunto de entrenamiento limita estructuralmente la capacidad de generalización del modelo sobre colisiones de alta energía. Las curvas de aprendizaje y el diagrama de dispersión correspondientes se presentan en las Figura 15 y Figura 16 respectivamente.




Figura 15: Curvas de aprendizaje del Error Absoluto Medio (MAE) para el modelo MLP entrenado con el Pipeline de Preprocesamiento 3




Figura 16: Diagrama de dispersión entre velocidades predichas y velocidades reales para el modelo MLP entrenado con el Pipeline de Preprocesamiento 3

4. XGBoost con Pipeline de Preprocesamiento 3

El cuarto experimento evaluó un modelo de potenciación de gradiente basado en árboles de decisión (XGBoost) entrenado sobre el mismo conjunto de 7 características seleccionadas por el Pipeline 3, con el propósito de contrastar el desempeño de un paradigma fundamentalmente distinto al neuronal sobre un espacio de entrada idéntico. El modelo alcanzó un MAE de prueba de 7.8 km/h, resultado que se sitúa a 0.5 km/h del obtenido por MLP-P3, configurando una diferencia de desempeño estadísticamente marginal entre ambas arquitecturas.

Este resultado tiene implicaciones de doble relevancia para la interpretación global de los experimentos. En primer lugar, la convergencia de dos familias de modelos estructuralmente distintas —redes neuronales completamente conectadas y ensambles de árboles potenciados mediante gradiente— hacia un error de prueba en el intervalo de 7 a 8 km/h sobre el mismo subconjunto de 7 características constituye evidencia robusta de que dicho conjunto de predictores captura efectivamente la información cinemática relevante para la estimación del delta-V precolisión. La consistencia del resultado con independencia del paradigma de aprendizaje refuerza la validez del proceso de selección de características implementado en el Pipeline 3. En segundo lugar, la ausencia de una ventaja decisiva de cualquiera de los dos modelos sugiere que el límite de desempeño alcanzable con la información tabular disponible se encuentra estructuralmente acotado en torno a los 7–8 km/h de error absoluto medio para este conjunto de datos, independientemente de la complejidad o la naturaleza del algoritmo empleado.

El análisis del diagrama de dispersión permite caracterizar con precisión la distribución espacial de los errores a lo largo del rango de velocidades. Para eventos con delta-V de hasta 80 km/h, las predicciones exhiben la mayor fidelidad del modelo, con puntos concentrados en la proximidad de la línea de identidad y una dispersión acotada que refleja una estimación consistente en el segmento de mayor densidad de observaciones. A partir de los 90 km/h, la dispersión de las predicciones se incrementa de forma progresiva, evidenciando la degradación gradual de la capacidad generalizadora del modelo conforme la velocidad se aleja del rango modal de entrenamiento. El caso de mayor error identificado en el conjunto de prueba corresponde a un evento con una velocidad real superior a 140 km/h, para el cual el modelo produjo una subestimación de aproximadamente 60 km/h, constituyendo el valor atípico de mayor magnitud registrado en los cuatro experimentos. Este caso extremo ilustra la limitación común a todas las configuraciones evaluadas: la escasa representación de colisiones de muy alta energía en el conjunto de datos impone un techo estructural a la capacidad predictiva del modelo en el extremo superior del espectro de severidad. El diagrama de dispersión correspondiente se presenta en la Fig. 17.

5. Análisis Comparativo

La Tabla 7 resume los resultados de las cuatro configuraciones experimentales en términos del MAE sobre los conjuntos de validación y prueba. El conjunto de resultados permite extraer tres observaciones principales.




Figura 17: Diagrama de dispersión entre velocidades predichas y velocidades reales para el modelo XGBoost entrenado con el Pipeline de Preprocesamiento 3

Primero, la selección de características implementada en el Pipeline 3 produjo el mejor desempeño de prueba entre las configuraciones de red neuronal, con un MAE de 7.3 km/h, lo que valida la utilidad de la etapa de filtrado por Información Mutua y correlación. Segundo, el modelo XGBoost entrenado con las mismas características obtuvo un desempeño de prueba de 7.8 km/h, confirmando la robustez del subconjunto de variables seleccionadas con independencia de la arquitectura del modelo. Tercero, las configuraciones MLP-P1 y MLP-P2 presentan errores de prueba similares (8.4 y 8.5 km/h respectivamente), lo que indica que la sustitución de One-Hot Encoding por Target Encoding, en ausencia de selección de características, no produce mejoras sustanciales en el desempeño predictivo final.

En conjunto, los resultados demuestran que es posible estimar la velocidad vehicular precolisión con un error absoluto medio inferior a 8.5 km/h utilizando exclusivamente variables tabulares derivadas de investigaciones forenses, sin recurrir al análisis de imágenes postcolisión, validando así la hipótesis central planteada en esta sección de la metodología.

TABLA 7: COMPARACIÓN DE MAE (KM/H) POR CONFIGURACIÓN EXPERIMENTAL

Config.	Pipeline	MAE Val.	MAE Test
MLP-P1	P1	7.1	8.4
MLP-P2	P2	11.6	8.5
MLP-P3	P3	11.9	7.3
XGBoost	P3	8.0	7.8

c. Resultados del Modelo Híbrido

Esta sección presenta los resultados obtenidos por la arquitectura multimodal *HybridVelocityEstimator*, desarrollada para integrar simultáneamente información visual proveniente de imágenes postcolisión y variables tabulares derivadas de procesos de reconstrucción de accidentes. El objetivo principal de esta evaluación consiste en determinar si la combinación de ambas modalidades permite mejorar la precisión de las estimaciones de velocidad precolisión respecto a los enfoques unimodales desarrollados previamente.

El desempeño del modelo fue evaluado mediante el Error Absoluto Medio (MAE) sobre los conjuntos de validación

y prueba, complementando el análisis con curvas de aprendizaje y diagramas de dispersión entre velocidades reales y estimadas. Los resultados obtenidos fueron posteriormente comparados con aquellos alcanzados por los modelos *ImageVelocityEstimator* y *TabularVelocityEstimator* con el propósito de cuantificar el impacto de la estrategia de fusión multimodal.

Los experimentos realizados mostraron una mejora consistente y significativa respecto a todos los enfoques desarrollados previamente. El modelo alcanzó un MAE de validación de 4.457 km/h y un MAE de prueba de 4.449 km/h, convirtiéndose en la arquitectura con mejor desempeño dentro de las alternativas evaluadas durante el proyecto.

Particularmente, se observó una reducción aproximada del 50% en el error de predicción respecto al modelo basado exclusivamente en imágenes. Asimismo, el modelo híbrido logró disminuir entre un 35% y un 40% el error obtenido por el mejor modelo basado únicamente en variables tabulares. Estas mejoras constituyen evidencia cuantitativa de que ambas modalidades contienen información complementaria y que su integración permite construir representaciones más completas del fenómeno estudiado.

Las curvas de aprendizaje obtenidas durante el entrenamiento evidencian un proceso de convergencia estable y consistente. Tanto las métricas de entrenamiento como las de validación muestran una disminución progresiva del error a lo largo de las épocas, sin divergencias significativas entre ambas curvas. Este comportamiento sugiere que la arquitectura fue capaz de aprovechar eficazmente la información adicional proporcionada por cada modalidad, generando representaciones más robustas y generalizables que las obtenidas mediante los enfoques unimodales.

La Figura 18 presenta las curvas de aprendizaje correspondientes al modelo *HybridVelocityEstimator*.




Figura 18: Curvas de aprendizaje del Error Absoluto Medio (MAE) para *HybridVelocityEstimator*.

El análisis de las predicciones permite observar con mayor detalle las mejoras alcanzadas mediante la estrategia multimodal. La Figura 19 muestra el diagrama de dispersión entre velocidades reales y velocidades estimadas sobre el conjunto de prueba.




Figura 19: Diagrama de dispersión entre velocidades reales y velocidades estimadas para HybridVelocityEstimator.

V. DISCUSIÓN

a. Interpretación de Hallazgos

Los resultados obtenidos a lo largo de los experimentos permiten extraer diversas observaciones relevantes sobre la capacidad de los modelos de inteligencia artificial para estimar la velocidad vehicular precolisión a partir de evidencia postimpacto. En términos generales, los tres enfoques desarrollados (basado en imágenes, basado en variables tabulares y multimodal) demostraron ser capaces de capturar información significativa relacionada con la severidad de las colisiones y utilizarla para aproximar la velocidad previa al impacto con niveles de error competitivos.

Uno de los hallazgos más relevantes corresponde al desempeño alcanzado por el modelo basado exclusivamente en imágenes. Los resultados obtenidos por ImageVelocityEstimator demostraron que las deformaciones estructurales visibles en fotografías postcolisión contienen información suficiente para que una red neuronal profunda aprenda representaciones asociadas con la velocidad de impacto. Este resultado respalda la hipótesis inicial de que los patrones de daño observables en la carrocería constituyen una manifestación indirecta de la energía involucrada durante el siniestro.

La evidencia más significativa de este comportamiento no proviene únicamente de las métricas de error obtenidas, sino también de la organización observada dentro del espacio latente generado por la red neuronal. Las visualizaciones de los embeddings mostraron agrupamientos coherentes con diferentes rangos de velocidad, indicando que el modelo logró construir representaciones semánticamente significativas del daño vehicular. Este hallazgo sugiere que las redes neuronales profundas son capaces de identificar características visuales relevantes para la estimación de velocidad incluso en ausencia de variables estructuradas complementarias.

Por otra parte, los resultados obtenidos mediante los modelos basados en variables tabulares demostraron que la información derivada de investigaciones forenses y procesos de reconstrucción de accidentes posee una elevada capacidad predictiva para la estimación del delta-V precolisión. Particularmente, los experimentos realizados evidenciaron que la selección adecuada de características tiene un impacto

considerable sobre el desempeño final del modelo. La mejora observada en MLP-P3 respecto a las configuraciones anteriores indica que la eliminación de variables redundantes o de baja relevancia permite construir representaciones más robustas y mejorar la capacidad de generalización sobre datos no observados.

Asimismo, la convergencia observada entre los resultados obtenidos por MLP-P3 y XGBoost constituye un hallazgo relevante desde una perspectiva metodológica. El hecho de que arquitecturas pertenecientes a paradigmas de aprendizaje distintos alcancen niveles de desempeño similares sugiere que el subconjunto de variables seleccionado captura efectivamente la información más relevante para la estimación de velocidad. Esta consistencia fortalece la validez del proceso de selección de características implementado y sugiere la existencia de un límite práctico de desempeño asociado exclusivamente a la información tabular disponible.

Sin embargo, el hallazgo más importante del estudio corresponde al desempeño alcanzado por la arquitectura multimodal HybridVelocityEstimator. La mejora significativa obtenida respecto a todos los enfoques unimodales proporciona evidencia sólida de que las modalidades visual y tabular contienen información complementaria sobre el fenómeno estudiado. Mientras que las imágenes permiten capturar información relacionada con la geometría del daño, la distribución de deformaciones y la severidad observable de la colisión, las variables tabulares aportan contexto técnico adicional asociado con las características del accidente y los vehículos involucrados.

La reducción del error obtenida mediante la fusión de ambas modalidades sugiere que ninguna de ellas resulta suficiente por sí sola para describir completamente la complejidad física de una colisión vehicular. En cambio, la integración conjunta permite construir representaciones más completas del evento, disminuyendo la incertidumbre presente en cada modalidad individual y mejorando la capacidad predictiva del modelo final.

Adicionalmente, los resultados obtenidos validan la estrategia de reutilización del encoder visual dentro de la arquitectura multimodal. Los embeddings generados por ImageVelocityEstimator demostraron contener información discriminativa valiosa sobre la severidad de los daños, funcionando como una representación compacta y altamente informativa que pudo integrarse exitosamente con variables estructuradas. Este resultado respalda la viabilidad del diseño modular propuesto y abre la posibilidad de continuar mejorando el encoder visual de manera independiente en futuras iteraciones del sistema.

En conjunto, los hallazgos obtenidos sugieren que la estimación automática de velocidad precolisión constituye un problema inherentemente multimodal. Tanto la evidencia visual como la información derivada de procesos de reconstrucción contienen señales relevantes para inferir la velocidad de impacto, y la combinación de ambas fuentes permite alcanzar niveles de precisión significativamente superiores a los obtenidos mediante enfoques unimodales.

b. Limitaciones

A pesar de los resultados obtenidos, el presente estudio presenta diversas limitaciones que deben considerarse al

interpretar los hallazgos y al evaluar el potencial de generalización de los modelos desarrollados.

La principal limitación identificada corresponde al tamaño y distribución del conjunto de datos disponible. Aunque el dataset construido permitió desarrollar y evaluar las arquitecturas propuestas, la cantidad total de muestras continúa siendo relativamente reducida para el entrenamiento de modelos de aprendizaje profundo. Esta situación resulta particularmente evidente en los rangos superiores de velocidad, donde la cantidad de observaciones disponibles disminuye considerablemente.

El desbalance presente en la distribución de velocidades constituye una segunda limitación importante. La mayoría de los casos analizados corresponden a colisiones de baja y media severidad, mientras que los accidentes de alta energía se encuentran significativamente subrepresentados. Como consecuencia, todos los modelos evaluados mostraron una tendencia consistente a incrementar sus errores de predicción conforme aumenta la velocidad real de los eventos analizados. Este comportamiento fue especialmente evidente para velocidades superiores a aproximadamente 65 km/h y representa el principal factor limitante para la generalización en escenarios de alta severidad.

Otra limitación relevante está asociada con la naturaleza de los datos utilizados como referencia. Las velocidades empleadas como variable objetivo provienen de procesos de reconstrucción forense y simulación de accidentes, los cuales, aunque constituyen la mejor aproximación disponible al valor real, siguen estando sujetos a incertidumbre inherente a los procedimientos de estimación. En consecuencia, los modelos fueron entrenados para aproximar reconstrucciones especializadas de la velocidad precolisión y no mediciones directas obtenidas durante el evento real.

Adicionalmente, el conjunto de datos utilizado proviene principalmente de casos documentados dentro del programa CIREN, lo que podría introducir sesgos relacionados con los criterios de selección de casos, las condiciones particulares de recopilación de evidencia y la distribución geográfica de los accidentes incluidos en la base de datos. Por esta razón, la capacidad de generalización de los modelos sobre poblaciones vehiculares diferentes o sobre contextos de operación distintos requiere ser validada mediante conjuntos de datos adicionales.

Finalmente, el modelo basado exclusivamente en imágenes presenta limitaciones inherentes a la naturaleza de la información visual disponible. Aunque las deformaciones observables contienen información relevante sobre la severidad del impacto, existen múltiples factores físicos que influyen en la dinámica de una colisión y que no pueden inferirse completamente a partir de fotografías postimpacto aisladas. Esta observación constituye precisamente una de las motivaciones que condujo al desarrollo del enfoque multimodal propuesto.

En consecuencia, los resultados presentados deben interpretarse como una validación inicial de la viabilidad del enfoque planteado y como una base para investigaciones futuras orientadas a incrementar la cantidad, diversidad y calidad de los datos disponibles.

VI. CONCLUSIONES

a. Resumen final

El presente trabajo investigó la viabilidad de estimar automáticamente la velocidad vehicular precolisión mediante técnicas de inteligencia artificial aplicadas a evidencia obtenida durante procesos de reconstrucción de accidentes. Para ello se desarrollaron y evaluaron tres enfoques complementarios: un modelo basado exclusivamente en imágenes postcolisión, un conjunto de modelos basados en variables tabulares derivadas de investigaciones forenses y una arquitectura multimodal capaz de integrar simultáneamente ambas fuentes de información.

Los resultados obtenidos demostraron que las deformaciones estructurales visibles en vehículos siniestrados contienen información significativa relacionada con la velocidad de impacto y que dicha información puede ser capturada mediante técnicas modernas de visión computacional. Asimismo, se comprobó que las variables tabulares derivadas de procesos de reconstrucción poseen una elevada capacidad predictiva y permiten estimar la velocidad precolisión con niveles de error competitivos.

El hallazgo principal del estudio corresponde al desempeño alcanzado por la arquitectura multimodal HybridVelocityEstimator. La integración de embeddings visuales con variables estructuradas permitió obtener mejoras sustanciales respecto a todos los enfoques unimodales evaluados, validando la hipótesis de que ambas modalidades contienen información complementaria sobre el fenómeno físico subyacente.

Los resultados obtenidos evidencian que la estimación automática de velocidad precolisión constituye un problema inherentemente multimodal y que la combinación de información visual y contextual permite construir representaciones más completas y precisas de los accidentes vehiculares. En este sentido, el enfoque propuesto demuestra el potencial de las técnicas de inteligencia artificial como herramientas de apoyo para procesos de análisis forense y reconstrucción de accidentes.

Adicionalmente, el diseño modular implementado permitió demostrar la utilidad de reutilizar representaciones visuales aprendidas mediante transferencia de conocimiento, favoreciendo la escalabilidad, mantenibilidad y evolución futura del sistema. Este enfoque abre nuevas posibilidades para el desarrollo de soluciones multimodales capaces de incorporar información proveniente de múltiples fuentes dentro de entornos de investigación forense automatizada.

b. Trabajo futuro

Los resultados obtenidos durante esta investigación abren múltiples líneas de trabajo orientadas a mejorar tanto el desempeño predictivo como la capacidad de generalización de las arquitecturas desarrolladas.

La dirección más inmediata consiste en ampliar el conjunto de datos disponible, particularmente mediante la incorporación de casos correspondientes a colisiones de alta energía. Una representación más equilibrada de todo el espectro de velocidades permitiría reducir las limitaciones asociadas al desbalance actualmente observado y mejorar el desempeño de los modelos sobre eventos de alta severidad.

De manera complementaria, futuras investigaciones podrían explorar estrategias avanzadas de aprendizaje multimodal, incluyendo mecanismos de atención, técnicas de fusión intermedia y arquitecturas basadas en transformadores multimodales. Estos enfoques podrían permitir una integración más profunda entre las modalidades visual y tabular, favoreciendo la captura de relaciones complejas entre ambas fuentes de información.

Otra línea prometedora consiste en continuar la evolución independiente del encoder visual mediante el entrenamiento sobre conjuntos de imágenes significativamente más grandes y diversos. Dado que la arquitectura propuesta desacopla la generación de embeddings visuales del proceso de aprendizaje multimodal, cualquier mejora obtenida en la calidad de estas representaciones podría transferirse directamente al sistema híbrido sin necesidad de rediseñar su estructura general.

Asimismo, resultaría valioso incorporar nuevas fuentes de información al proceso de estimación, tales como datos de telemetría vehicular, información proveniente de registradores de eventos, características geométricas detalladas de los vehículos involucrados o reconstrucciones tridimensionales obtenidas mediante técnicas fotogramétricas.

Finalmente, futuras investigaciones deberían evaluar la capacidad de generalización de los modelos sobre conjuntos de datos independientes, procedentes de diferentes regiones geográficas, tipos de vehículos y contextos de operación. Este proceso permitiría validar la robustez del enfoque propuesto y avanzar hacia el desarrollo de sistemas capaces de asistir de manera confiable en escenarios reales de reconstrucción y análisis forense de accidentes vehiculares.

REFERENCIAS

- [1] World Health Organization, "Road traffic injuries," 2023, WHO Fact Sheet. [Online]. Available: <https://www.who.int/news-room/fact-sheets/detail/road-traffic-injuries>
- [2] R. M. Brach and R. M. Brach, *Vehicle Accident Analysis and Reconstruction Methods*, 2nd ed. SAE International, 2011.
- [3] L. B. Fricke, *Traffic Accident Reconstruction*, ser. Traffic Accident Investigation Manual. Northwestern University Traffic Institute, 1990, vol. 2.
- [4] D. E. Struble, *Automotive Accident Reconstruction: Practices and Principles*. CRC Press, 2014.
- [5] A. Mrowicki, M. Krukowski, F. Turoboś, and P. Kubiak, "Determining vehicle pre-crash speed in frontal barrier crashes using artificial neural network for intermediate car class," *Forensic Science International*, vol. 308, p. 110179, 2020.
- [6] B. G. McHenry, "The algorithms of crash," in *SAE Technical Paper 2001-01-0877*, 2001.
- [7] J. F. Kerkhoff, "Photographic techniques for accident reconstruction," in *SAE Technical Paper 850248*, 1985.
- [8] T. Linder, "Photography for accident reconstruction, product liability, and testing," 2016, sAE International Course C1729. [Online]. Available: <https://www.sae.org/learn/content/C1729/>
- [9] National Highway Traffic Safety Administration, "Crash injury research and engineering network (ciren)," 2024, u.S. Department of Transportation. [Online]. Available: <https://www.nhtsa.gov/research-data/crash-injury-research>
- [10] M. A. Rahim and H. M. Hassan, "A deep learning based traffic crash severity prediction framework," *Accident Analysis & Prevention*, vol. 154, p. 106090, 2021.
- [11] B. van Ruitenbeek and S. Bhulai, "Convolutional neural networks for vehicle damage detection," *Machine Learning with Applications*, vol. 8, p. 100433, 2022.
- [12] S. M. Jameel *et al.*, "Automatic damaged vehicle estimator using enhanced deep learning algorithm," *Machine Learning with Applications*, vol. 11, p. 100332, 2023.
- [13] K. Patil, M. Kulkarni, A. Sriraman, and S. Karande, "Deep learning based car damage classification," in *Proceedings of the 16th IEEE International Conference on Machine Learning and Applications (ICMLA)*, 2017, pp. 50–54.
- [14] M. Hasan, C. Nguyen, Y. Boo, H. Jahani, and K. Ong, "Vehicle damage detection using artificial intelligence: A systematic literature review," *WIREs Data Mining and Knowledge Discovery*, vol. 15, no. 2, 2025.
- [15] J. Argote *et al.*, "Estimating automobile crash characteristics from images using deep learning," in *Proceedings of the International FLAIRS Conference*, vol. 35, 2022. [Online]. Available: <https://journals.flvc.org/FLAIRS/article/view/130629>
- [16] X. Zhao *et al.*, "A deep neural network inverse solution to recover pre-crash impact data of car collisions," *Transportation Research Part C: Emerging Technologies*, vol. 126, p. 103069, 2021.
- [17] W. Czajewski *et al.*, "Non-linear method of vehicle pre-crash velocity estimation based on random forest regression and energy equivalent speed for compact vehicle class," *Energies*, vol. 19, no. 7, p. 1678, 2026.
- [18] I. Cioroianu *et al.*, "Determining vehicle pre-crash speed in frontal barrier crashes using artificial neural network for intermediate car class," *Forensic Science International*, vol. 309, p. 110213, 2020.
- [19] P. M. Kyu and K. Woraratpanya, "Car damage detection and classification," in *Proceedings of the 2020 2nd International Conference on Image Processing and Machine Vision (IPMV)*, 2020. [Online]. Available: <https://dl.acm.org/doi/10.1145/3406601.3406651>
- [20] T. Bhowmik and R. Rateria, "Deep learning based multi-modal data fusion for car crash detection," in *2023 8th International Conference on Computers and Devices for Communication (CODEC)*, 2023, pp. 1–2.
- [21] X. Liu *et al.*, "A multimodal deep learning approach for predicting traffic accident severity using crash records, road geometry, and textual descriptions," *Computer-Aided Civil and Infrastructure Engineering*, 2025.
- [22] S. Somvanshi *et al.*, "Machine learning and deep learning for predicting traffic crash injury severity: A systematic review and meta-analysis (2014–2025)," *Journal of Road Safety*, 2026. [Online]. Available: <https://journalofroadsafety.org/article/156042>